AIDE DECISIONNELLE

Bienvenue dans ce Notebook traitant d'un exemple d'aide décisionnelle. Ce Notebook est mon premier projet et avait pour but d'apprendre à manipuler Pandas, numpy et matplotlib. La qualité du code n'est pas la chose qui nous importe ici. Ce qui nous intéresse c'est plutôt la réflexion que l'on doit avoir quand on traite un sujet aboutissant à une aide décisionnelle. A savoir :

- Réflexion
- Analyse
- Livrables (graphiques) à présenter au client sur un support spécifique (Word, Powerpoint, etc.)

Aller, c'est parti! Je vais tenter d'être le plus clair possible dans mes commentaires. Bon courage!

Programme d'analyse des systèmes éducatifs mondiaux.

Le but est d'analyser si les données sur l'éducation fournies par la banque mondiale permettent d'informer si Academy, entreprise de formations en ligne niveau lycée et universitépeut s'étendre à l'international.

Les questions posées par le client :

- Quels sont les pays avec un fort potentiel de clients pour nos services ?
- Pour chacun de ces pays, quelle sera l'évolution de ce potentiel de clients ?
- Dans quels pays l'entreprise doit-elle opérer en priorité ?

Le travail consiste à :

- Valider la qualité de ce jeu de données (comporte-t-il beaucoup de données manquantes, dupliquées ?)
- Décrire les informations contenues dans le jeu de données (nombre de colonnes ? nombre de lignes ?)
- Sélectionner les informations qui semblent pertinentes pour répondre à la problématique (quelles sont les colonnes contenant des informations qui peuvent être utiles pour répondre à la problématique de l'entreprise ?)
- Déterminer des ordres de grandeurs des indicateurs statistiques classiques pour les différentes zones géographiques et pays du monde (moyenne/médiane/écart-type par pays et par continent ou bloc géographique)

Les ressources :

- Le lien de téléchargement des données : https://datacatalog.worldbank.org/dataset/education-statistics
- Le site de la banque mondiale de données : http://datatopics.worldbank.org/education/

In [32]:
```python
#On commence par appeler les librairies nécessaires au projet
#Numpy est une librairie contenant les fonctions de mathématiques
#Pandas est une librairie permettant de manipuler facilement les dataset
import numpy as np
import pandas as pd

import matplotlib.pyplot as plt
```

In [2]:
```python
#On charge les csv nécessaires à l'étude en cours
stats_data = pd.read_csv('EdStatsData.csv')
country_data = pd.read_csv('EdStatsCountry.csv')
footnote_data = pd.read_csv('EdStatsFootNote.csv')
series_data = pd.read_csv('EdStatsSeries.csv')
country_series_data = pd.read_csv('EdStatsCountry-Series.csv')
```

Commençons d'abord par étudier la structure du dataset étudié : stats_data

Nous allons calculer :

- Le nombre de lignes totales (1 ligne = 1 indicateur)
- Le nombre d'indicateurs par régions ou pays

In [3]:
```python
#On regarde le nombre de lignes et de colonnes
stats_data.shape
```

Out[3]: (886930, 70)

In [4]:
```python
#On calcule le nombre d'indicateurs utiles par région
nbr_indicateurs = pd.Series(stats_data['Country Name'].value_counts())

nbr_indicateurs = pd.DataFrame({'Région':nbr_indicateurs.index, 'Nbr Indicateurs':nbr_indicateurs.values})
nbr_indicateurs.head()
```

Out[4]:

	Région	Nbr Indicateurs
0	Brazil	3665
1	Estonia	3665
2	Iran, Islamic Rep.	3665
3	High income	3665
4	Mali	3665

La première partie de l'exercice consiste à séparer les données par région et par pays.

Le datatset stats_data est rangé de tel sorte que les régions sont classées en premier jusqu'à la ligne 'World' de la colonne 'Country name'. Ensuite nous avons les pays.

Le premier exercice consiste à diviser le dataframe en 2 :

- Un par régions
- Un par pays

Ensuite, nous étudierons le taux de remplissage des données dans chaque dataframe pour répondre à la question : "Quel est le taux de données manquantes dans le dataset fournit en entrée?" Pour cela, on enlevera d'abord les lignes où il n'y a aucune donnée d'indicateur.

In [5]:
```python
#On recherche la limite des régions dans le dataset de départ
#Cela nous permettra de spliter le dataframe en 2 par la suite
ligne_split = stats_data[stats_data['Country Name'] == 'World']
```

In [6]:
```python
#On crée le dataframe contenant les données par régions
data_par_regions = stats_data.loc[:91624,:]
data_par_regions.shape
```

Out[6]: (91625, 70)

In [7]:
```python
#"Quel est le taux de données manquantes dans le dataset fournit en entrée?"
#Nous allons calculer le taux de remplissage de données par régions
nbr_donnees_totales = data_par_regions.shape[0] * data_par_regions.shape[1]
nbr_donnees_totales

nbr_donnees_nulles = data_par_regions.isnull().sum().sum()
nbr_donnees_nulles

taux_remplissage_regions = (nbr_donnees_nulles / nbr_donnees_totales)*100
taux_remplissage_regions
```

Out[7]: 89.79603196258039

In [8]:
```python
#On teste s'il y a des lignes dupliquées
#Si la valeur de data_par_regions.shape[0] = à la valeur précédente, alors il n'y a pas d'élément dupliqué
data_par_regions.drop_duplicates()
data_par_regions.shape
```

Out[8]: (91625, 70)

In [9]:
```python
#On supprime toutes les lignes où aucune année ne contient de données
#La fonction dropna() sert à supprimer des lignes contenant des cellules vides NaN.

#On commence par créer une liste avec les cellules à tester
colonnes_a_tester = list(data_par_regions.loc[:,"1970":])

#Ensuite,on utilise le dropna()
#le paramètre how='all' configure la fonction pour qu'il teste que TOUTES les cellules soient vides
#Le subset, c'est la plage de cellules à tester. Celle qu'on a déterminé précédemment.
data_par_regions = data_par_regions.dropna(how="all", subset=colonnes_a_tester)

data_par_regions.shape
```

Out[9]: (9312, 70)

In [10]:
```python
#On crée le dataframe contenant les données par pays
data_par_pays = stats_data.loc[91625:,:]
data_par_pays.shape
```

Out[10]: (795305, 70)

In [11]:
```python
#On calcule le nombre de pays total
nbr_pays_total = data_par_pays['Country Code'].unique()
nbr_pays_total = nbr_pays_total.shape[0]
nbr_pays_total
```

Out[11]: 217

In [12]:
```python
#"Quel est le taux de données manquantes dans le dataset fournit en entrée?"
#Nous allons calculer le taux de remplissage de données par pays
nbr_donnees_totales = data_par_pays.shape[0] * data_par_pays.shape[1]
nbr_donnees_totales

nbr_donnees_nulles = data_par_pays.isnull().sum().sum()
nbr_donnees_nulles

taux_remplissage_pays = (nbr_donnees_nulles / nbr_donnees_totales)*100
taux_remplissage_pays
```

Out[12]: 85.67402443087872

In [13]:
```python
#On teste s'il y a des lignes dupliquées
data_par_pays.drop_duplicates()
data_par_pays.shape
```

Out[13]: (795305, 70)

In [14]:
```python
#On supprime toutes les lignes où aucune année ne contient de données
#La fonction dropna() sert à supprimer des lignes contenant des cellules vides NaN.

#On commence par créer une liste avec les cellules à tester
colonnes_a_tester = list(data_par_pays.loc[:,"1970":])

#Ensuite,on utilise le dropna()
#le paramètre how='all' configure la fonction pour qu'il teste que TOUTES les cellules soient vides
#Le subset, c'est la plage de cellules à tester. Celle qu'on a déterminé précédemment.
data_par_pays = data_par_pays.dropna(how="all", subset=colonnes_a_tester)

data_par_pays.shape
```

Out[14]: (348093, 70)

Nous avons maintenant 2 dataframes. Un avec les données par régions, l'autre par pays. Nous avons également les taux de remplissage de chaque dataframe.

Il serait intéressant de voir dans un tableau récapitulatif :

- le nombre de régions
- le nombre d'indicateurs par région
- la moyenne d'indicateur par région

Pour les pays :

- le nombre de pays
- le nombre d'indicateurs par pays
- la moyenne d'indicateur par pays

In [15]:
```python
#On calcule le nombre d'indicateurs utiles par région
indicateurs_regions = pd.Series(data_par_regions['Country Name'].value_counts())

indicateurs_regions = pd.DataFrame({'Région':indicateurs_regions.index, 'Nbr Indicateurs':indicateurs_region
indicateurs_regions.head()
```

Out[15]:

	Région	Nbr Indicateurs
0	World	663
1	Sub-Saharan Africa	382
2	Sub-Saharan Africa (excluding high income)	382
3	Latin America & Caribbean (excluding high income)	379
4	Middle East & North Africa (excluding high inc...	375

In [16]:
```python
#Même exercice pour les pays
indicateurs_pays = pd.Series(data_par_pays['Country Name'].value_counts())

indicateurs_pays = pd.DataFrame({'Pays':indicateurs_pays.index, 'Nbr Indicateurs':indicateurs_pays.values})
indicateurs_pays.shape
```

Out[16]: (217, 2)

In [17]:
```python
#On calcule le nombre de pays qui ont au minimum un indicateur
nbr_pays = data_par_pays['Country Code'].unique()
nbr_pays = nbr_pays.shape[0]
nbr_pays
```

Out[17]: 217

In [18]:
```python
#On calcule le nombre total d'indicateurs pour les régions
nbr_indicateurs_regions = indicateurs_regions['Nbr Indicateurs'].sum()
nbr_indicateurs_regions
```

Out[18]: 9312

In [19]:
```python
#On calcule le nombre total d'indicateurs pour les pays
nbr_indicateurs_pays = indicateurs_pays['Nbr Indicateurs'].sum()
nbr_indicateurs_pays
```

Out[19]: 348093

In [20]:
```python
#On calcule la moyenne des indicateurs par régions
moyenne_indic_regions = indicateurs_regions['Nbr Indicateurs'].mean()
moyenne_indic_regions
```

Out[20]: 372.48

In [21]:
```python
#On calcule la moyenne des indicateurs par pays
moyenne_indic_pays = indicateurs_pays['Nbr Indicateurs'].mean()
moyenne_indic_pays
```

Out[21]: 1604.115207373272

In [22]:
```python
labels = indicateurs_regions['Région']
sizes = indicateurs_regions['Nbr Indicateurs']
#colors = ['yellowgreen', 'gold', 'lightskyblue', 'lightcoral']

plt.pie(sizes, labels=labels, shadow=True, startangle=75)

plt.axis('equal')

#plt.savefig('PieChart01.png')
plt.show()
```

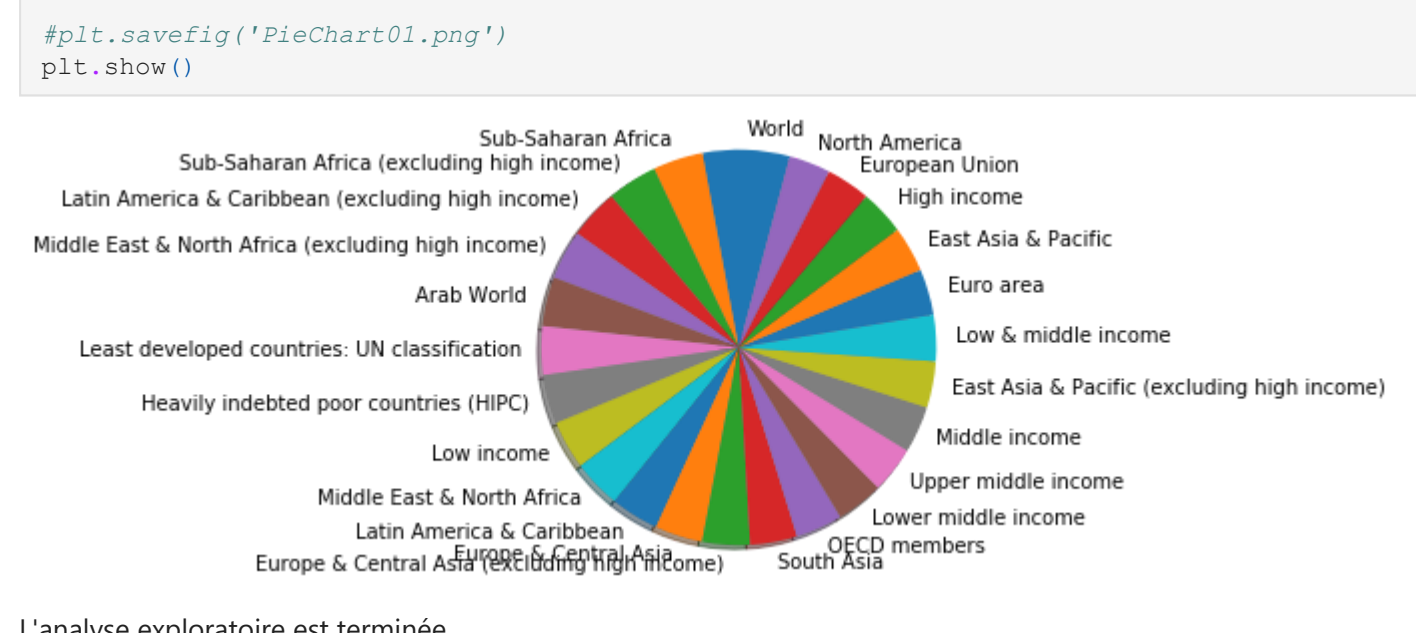

L'analyse exploratoire est terminée.

Afin de commencer une analyse plus fine des données, nous allons coder quelques fonctions qui nous aideront à alléger le code.

In [23]:
```python
#Permet de calculer, dans le dataset de base, le taux de remplissage de données pour un indicateur choisi
#Le tri se fera par le prefixe de l'indicateur ou par son nom complet
#La fonction retournera un dataframe

def recherche_indicateur(df, prefixe):

    #Nous allons créer un tableau contenant tous les indicateurs se rapportant au prefixe avec le taux de
    #remplissage de données pour chaque indicateur.
    tri_indicateurs = pd.DataFrame(columns=['Pays','Code Indicateur','Taux de remplissage'])

    #Nous bouclons sur la liste des régions
    for i in df.itertuples():

        if prefixe in df.loc[i[0],'Indicator Code']:

            #On analyse les données sur 7 colonnes de 2010 à 2016
            nbr_donnees_totales = 7
            nbr_donnees_nulles = df.loc[i[0],'2010':'2016'].isnull().sum().sum()
            taux_remplissage_indicateur = 100-(nbr_donnees_nulles / nbr_donnees_totales)*100

            #On incrémente ensuite le tableau de sortie
            tri_indicateurs = \
                tri_indicateurs.append({'Pays':df.loc[i[0],'Country Name'], \
                                        'Code Indicateur':df.loc[i[0],'Indicator Code'], \
                                        'Taux de remplissage':taux_remplissage_indicateur}, ignore_i

    return tri_indicateurs
```

In [24]:
```python
#Permet de trier le dataset de base suivant un indicateur choisi et de faire le tri dans les années à analys
#La fonction retournera un dataframe

def filtre_indicateur(df, indicateur):

    masque = df['Indicator Code'] ==  indicateur

    pays_filtres = df[masque]

    return pays_filtres
```

In [25]:
```python
#Permet de créer un tableau avec les indicateurs utiles pour le choix d'un pays en fonction du pays choisi
#La fonction retournera un dataframe

def analyse_pays(df, pays):

    df_analyse = df[df['Country Name'].isin([pays])]
    df_analyse = df_analyse[df_analyse['Indicator Code']\
                            .isin(['SE.TER.ENRL', 'NY.GDP.PCAP.CD',\
                                   'IT.NET.USER.P2','SE.SEC.ENRL.GC','SP.POP.TOTL'])]

    df_analyse = df_analyse.reset_index(drop=True)
    return df_analyse
```

Recherche des indicateurs utiles et pertinents pour l'analyse :

Deux approches différentes pour construire notre analyse :

- Approche 1 : les pays à fort potentiel sont les pays avec les populations les plus riches et ayant le plus facilement accès à internet.
  - D'abord analyser la région ayant le taux d'accès le plus élevé.
  - Ensuite, analyser les pays qui se trouvent dans cette région.
  - Indicateur pour le taux d'accès à internet (pour 100 personnes) : IT.NET.USER.P2
  - Indicateur du PIB par habitant ($) : NY.GDP.PCAP.CD
- Approche 2 : les pays à fort potentiel sont les pays avec le nombres d'inscriptions en enseignements secondaire et supérieur le plus élevé.
  - D'abord analyser les pays avec le taux d'inscriptions en enseignement secondaire le plus élevé.
  - Ensuite analyser les pays avec le taux d'inscriptions en enseignement supérieur le plus élevé.
  - Inscription en secondaire général, les deux sexes : SE.SEC.ENRL.GC
  - Inscription dans l'enseignement supérieur, tous les programmes, les deux sexes : SE.TER.ENRL

Chaque approche débouchera sur quelques pays les plus intéressant pour l'entreprise. Un récapitulalif de ces pays sera établi. Il comportera les informations suivantes :

- Taux d'accès à internet
- PIB par habitant
- Populations totales : SP.POP.TOTL
- Nbr d'inscriptions en secondaire
- Nbr d'inscriptions en supérieur

Comment trouver les indicateurs qui nous intéresse ici?

- En faisant des recherches sur internet par exemple, notament sur le site de la Banque Mondiale des données dont le lien est au début de ce Notebook.
- En recherchant des mots clés dans les définitions des indicateurs que l'on peut trouver dans le dataset country_series_data (Ex. "GDP per capita" (traduction du PIB par habtant en anglais) ou encore "internet")

In [28]:
```python
#D'abord analyser la région ayant le taux d'accès le plus élevé.

#On filtre le dataset de départ regroupant les régions par l'indicateur de taux d'accès à internet
data_par_regions_internet = filtre_indicateur(data_par_regions,'IT.NET.USER.P2')
data_par_regions_internet = data_par_regions_internet.sort_values(by = '2016', ascending = False)
data_par_regions_internet = data_par_regions_internet.reset_index(drop = True)
data_par_regions_internet.shape
```

Out[28]: (25, 70)

In [29]:
```python
data_par_regions_internet['2016'].describe()
```

Out[29]:
```
count    22.000000
mean     45.617993
std      21.771998
min      12.497428
25%      27.312665
50%      46.765849
75%      56.231258
max      81.967715
Name: 2016, dtype: float64
```

In [341…
```python
#Analyse de la connexion internet par régions

data = list(data_par_regions_internet['2016'].dropna())

fig, ax = plt.subplots(figsize=(6, 6))

ax.grid(True)

ax.boxplot(data,whis=[5,95])

ax.text(1.1, 46, 'Médiane', fontsize = 10, color = 'coral')
ax.text(1.1, 15, '5% de la population', fontsize = 10, color = 'black')
ax.text(1.1, 76, "95% de l'échantillon", fontsize = 10, color = 'black')

#On paramètre le graphique et on l'affiche
ax.set(ylim=[0,100],title="Analyse taux de connexions internet régions en 2016", ylabel='Pourcentage (%)')

#On enregistre le graphique
plt.savefig('evolution_internet_region.png', transparent = True, dpi = 700)

plt.show()
```

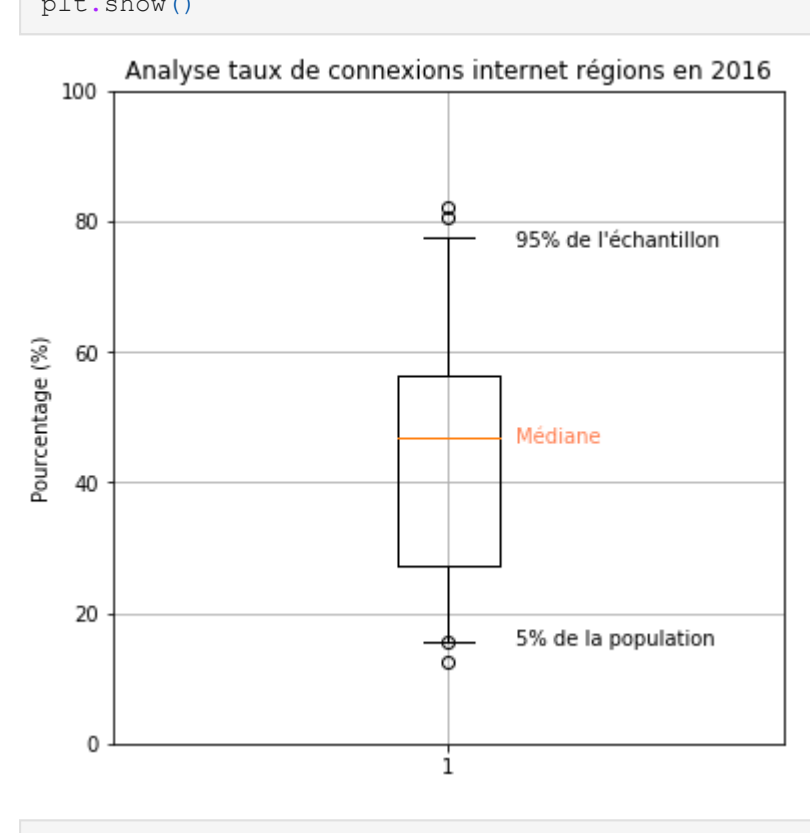

In [37]:
```python
#On va calculer le taux d'accès à internet par régions
acces_internet_regions = recherche_indicateur(data_par_regions,'IT.NET.USER.P2')
acces_internet_regions = acces_internet_regions.sort_values(by = 'Taux de remplissage', ascending = False)
acces_internet_regions.head(1)
```

Out[37]:

	Pays	Code Indicateur	Taux de remplissage
12	Low & middle income	IT.NET.USER.P2	100.0

In [38]:
```python
#On calcule la moyenne des taux de données utiles
moy_taux_acc_int_region = acces_internet_regions['Taux de remplissage'].mean()
moy_taux_acc_int_region
```

Out[38]: 94.85714285714286

In [40]:
```python
#On va superposer l'évolution des taux d'accès à internet de chaque région

annees = ['2010','2011','2012','2013','2014','2015','2016']

fig, ax = plt.subplots(figsize=(10, 10))

ax.grid(True)

#On trace les courbe de chaque région
for i in data_par_regions_internet.itertuples():

    ax.plot(annees, data_par_regions_internet.loc[i[0],'2010':'2016'],\
            label=data_par_regions_internet.loc[i[0],'Country Name'])

#On paramètre le graphique et on l'affiche
ax.set(title="Evolution des taux d'accès à internet", ylabel='Pourcentage (%)')
ax.legend(bbox_to_anchor = (1, 1), loc = 'upper left', prop = {'size': 10})

#On enregistre le graphique
plt.savefig('evolution_internet_region.png', transparent = True, dpi = 700)

plt.show()
```

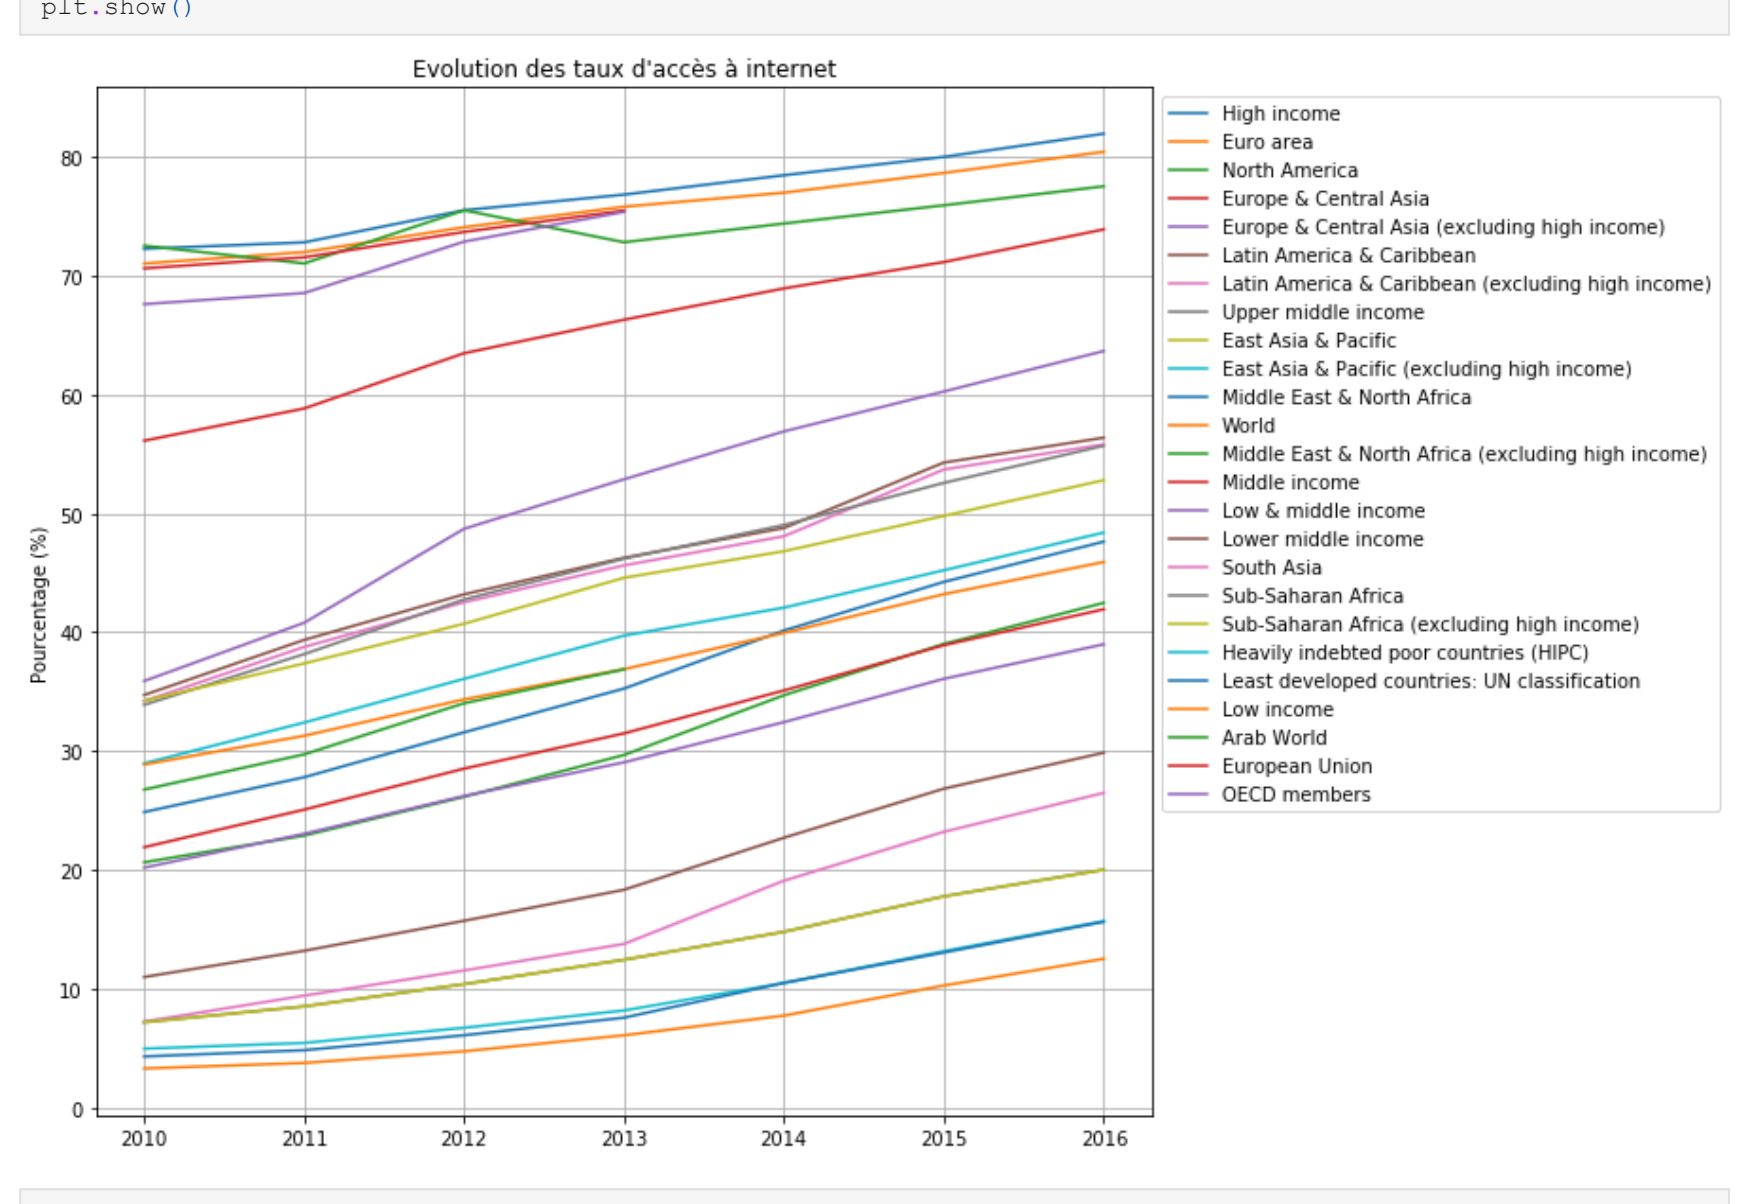

In [248…
```python
#Analyse du PIB par habitant des pays riches
data = list(pays_riches['2016'].dropna())

fig, ax = plt.subplots(figsize=(6, 6))

ax.boxplot(data)

#On paramètre le graphique et on l'affiche
ax.set(ylim=[0,60000],title="Analyse PIB par habitant en 2016", ylabel='(Dollars ($))')

#On enregistre le graphique
plt.savefig('Boite_moustache_PIB.png', transparent = True, dpi = 700)

plt.show()
```

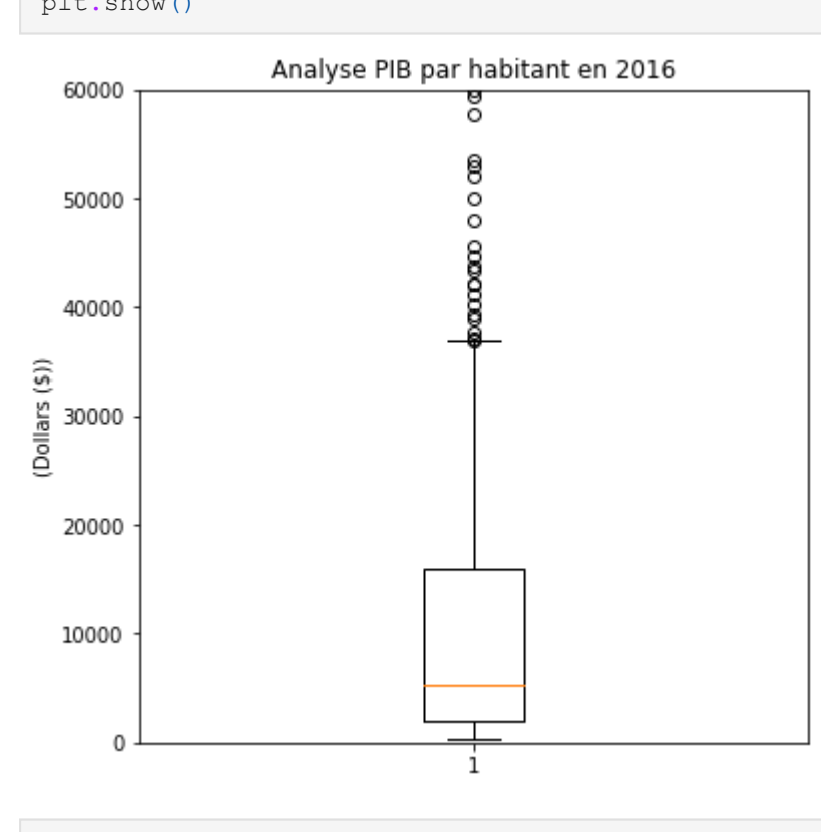

In [41]:
```python
#Maintenant, analysons quels sont les pays se trouvant dans la région high income
#Ces données se trouvent dans le dataframe country_data

pays_region_principale = country_data.loc[country_data['Region'] == 'High income',:]
pays_region_principale.shape

#Le résultat étant nul, nous allons faire une analyse par pays avec les plus hauts revenus
```

Out[41]: (0, 32)

In [42]:
```python
#On crée un tableau pour analyser les pays les plus riches
#Pour cela, on utilise l'indicateur du PIB par habitant
pays_riches = filtre_indicateur(data_par_pays,'NY.GDP.PCAP.CD')
pays_riches = pays_riches.sort_values(by = '2016', ascending = False)
pays_riches = pays_riches.reset_index(drop = True)
pays_riches.shape
```

Out[42]: (209, 70)

In [43]:
```python
#On calcule la moyenne des données
taux_donnees_pays_riches = recherche_indicateur(data_par_pays,'NY.GDP.PCAP.CD')
moy_taux_pays_riches = taux_donnees_pays_riches['Taux de remplissage'].mean()
moy_taux_pays_riches
```

Out[43]: 94.80519480519482

In [44]:
```python
#On analyse le PIB de tous les pays
#Je vais récupérer l'écart-type ainsi que la moyenne pour le tracer sur le graphique juste après.
#Cela n'apporte pas un grand intérêt à l'analyse mais cela répond à la demande de l'exercice.
pays_riches['2016'].describe()
```

Out[44]:
```
count       189.000000
mean      13308.833845
std       18042.544985
min         285.727442
25%        1900.201479
50%        5219.109408
75%       15891.626549
max      100573.139978
Name: 2016, dtype: float64
```

In [45]:
```python
#On fait un graphique en barre des pays les plus riches
name = pays_riches['Country Name']
data = pays_riches['2016']

#On dimensionne le graphique
fig, ax = plt.subplots(figsize=(8, 8))

#On paramètre les barres avec les données et les labels
ax.bar(name, data)

#On paramètre la ligne de la moyenne
ax.axhline(data.mean(), ls='--', color='r')

#On paramètre la ligne de l'écart-type sup
ax.axhline(data.mean() + data.std(), ls='--', color='g')

#On paramètre la ligne de l'écart-type inf
ax.axhline(data.mean() - data.std(), ls='--', color='g')

#On dit que les labels vont sur l'axe X
labels = ax.get_xticklabels()
#On les réoriente à 45°
plt.setp(labels, rotation=45)

#On paramètre le grtaphique et on l'affiche
ax.set(xlim=[-0.5, 15], ylabel='Dollars ($)',
       title="PIB par habitant en 2016")

#On enregistre le graphique
plt.savefig('PIB.png', transparent = True, dpi = 700)
#plt.close()
```

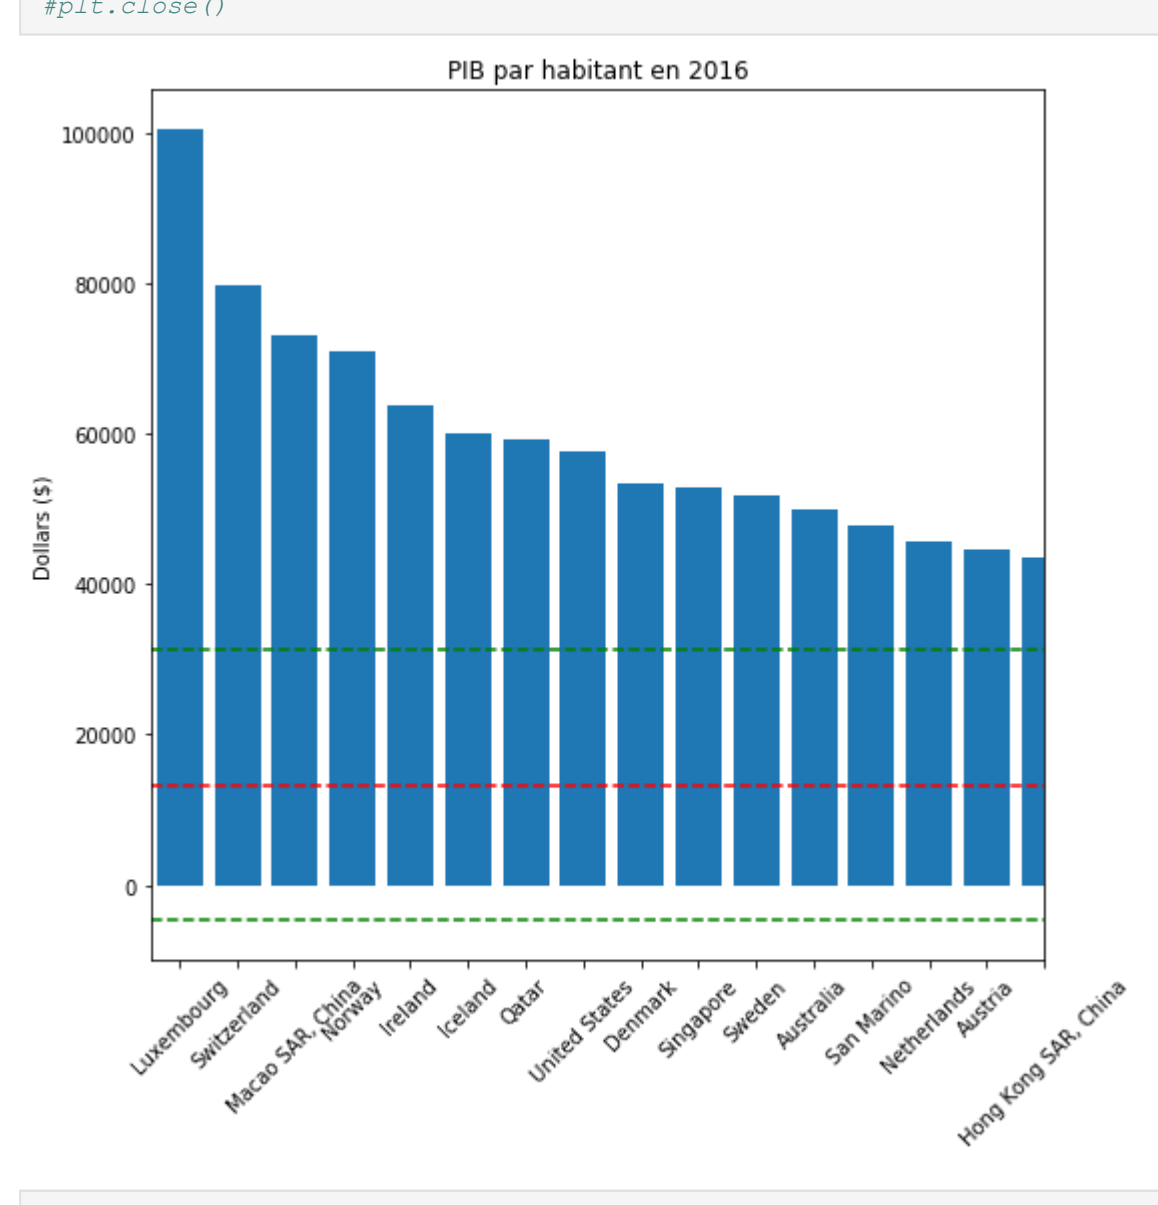

In [110…
```python
#Petits essais avec le mentor
mediane = pays_riches['2016'].median()
mediane

masque = pays_riches['2016'] > mediane
df = pays_riches[masque]
df

liste = df['Country Name'].values
liste
```

Out[110…
```
array(['Luxembourg', 'Switzerland', 'Macao SAR, China', 'Norway',
       'Ireland', 'Iceland', 'Qatar', 'United States', 'Denmark',
       'Singapore', 'Sweden', 'Australia', 'San Marino', 'Netherlands',
       'Austria', 'Hong Kong SAR, China', 'Finland', 'Canada', 'Germany',
       'Belgium', 'United Kingdom', 'New Zealand', 'Japan',
       'United Arab Emirates', 'Israel', 'Andorra', 'France', 'Guam',
       'Italy', 'Bahamas, The', 'Korea, Rep.', 'Kuwait',
       'Brunei Darussalam', 'Spain', 'Malta', 'Cyprus', 'Bahrain',
       'Northern Mariana Islands', 'Slovenia', 'Saudi Arabia', 'Portugal',
       'Czech Republic', 'Greece', 'Estonia', 'St. Kitts and Nevis',
       'Slovak Republic', 'Trinidad and Tobago', 'Barbados', 'Uruguay',
       'Seychelles', 'Oman', 'Lithuania', 'Antigua and Barbuda', 'Palau',
       'Latvia', 'Chile', 'Panama', 'Hungary', 'Argentina', 'Poland',
       'Croatia', 'American Samoa', 'Costa Rica', 'Turkey', 'Maldives',
       'Grenada', 'Mauritius', 'Romania', 'Malaysia', 'St. Lucia',
       'Russian Federation', 'Equatorial Guinea', 'Brazil', 'Lebanon',
       'Mexico', 'China', 'Dominica', 'Kazakhstan', 'Bulgaria', 'Gabon',
       'Montenegro', 'St. Vincent and the Grenadines', 'Botswana',
       'Dominican Republic', 'Turkmenistan', 'Peru', 'Ecuador',
       'Thailand', 'Suriname', 'Colombia', 'Serbia', 'South Africa',
       'Macedonia, FYR', 'Fiji'], dtype=object)
```

In [50]:
```python
#Nous allons maintenant analyser les évolutions des pays les plus intéressants pour l'entreprise
#Pour cela on commence par trier les 8 pays au plus fort PIB par habitant

analyse_PIB = data_par_pays[data_par_pays['Country Name'].isin(['Luxembourg','Switzerland',\
                                        'Macao SAR, China','Norway','Ireland','Iceland','Qatar','United Sta

analyse_PIB = analyse_PIB[analyse_PIB['Indicator Code']\
                          .isin(['SE.TER.ENRL', 'NY.GDP.PCAP.CD',\
                                 'IT.NET.USER.P2','SE.SEC.ENRL.GC','SP.POP.TOTL'])]

analyse_PIB = analyse_PIB.reset_index(drop=True)

#On enregistre le tableau dans un doc excel
#fichier_excel = pd.ExcelWriter('Analyse_pays.xlsx')
#analyse_PIB.to_excel(fichier_excel, "Sheet1")
#fichier_excel.save()

analyse_PIB
```

Out[50]:

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	19
0	Iceland	ISL	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	1.807400e+04	1.882300e+04	1.938200e+04	1.992100e+04	1.982900e+
1	Iceland	ISL	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	1.706000e+03	1.970000e+03	2.267000e+03	2.429000e+03	2.695000e+
2	Iceland	ISL	GDP per capita (current US$)	NY.GDP.PCAP.CD	2.597387e+03	3.278649e+03	4.047619e+03	5.481730e+03	7.098028e+03	6.506867e+
3	Iceland	ISL	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
4	Iceland	ISL	Population, total	SP.POP.TOTL	2.044380e+05	2.060980e+05	2.091370e+05	2.123170e+05	2.152090e+05	2.179790e+
5	Ireland	IRL	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	1.545750e+05	1.617960e+05	1.691760e+05	1.785570e+05	2.476090e+
6	Ireland	IRL	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	2.850100e+04	2.951700e+04	3.002000e+04	3.173700e+04	3.789700e+
7	Ireland	IRL	GDP per capita (current US$)	NY.GDP.PCAP.CD	1.488295e+03	1.705973e+03	2.082957e+03	2.427172e+03	2.519942e+03	2.976961e+
8	Ireland	IRL	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
9	Ireland	IRL	Population, total	SP.POP.TOTL	2.957250e+06	2.992050e+06	3.036850e+06	3.085950e+06	3.137500e+06	3.189550e+
10	Luxembourg	LUX	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	8.689000e+03	8.924000e+03	8.685000e+03	8.425000e+03	8.213000e+03	1.501300e+
11	Luxembourg	LUX	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	3.630000e+02	3.660000e+02	4.850000e+02	4.580000e+02	5.220000e+
12	Luxembourg	LUX	GDP per capita (current US$)	NY.GDP.PCAP.CD	4.449540e+03	4.591748e+03	5.680130e+03	7.709729e+03	9.282808e+03	9.008028e+
13	Luxembourg	LUX	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
14	Luxembourg	LUX	Population, total	SP.POP.TOTL	3.391710e+05	3.424210e+05	3.466000e+05	3.504500e+05	3.550500e+05	3.589500e+
15	Macao SAR, China	MAC	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	8.960000e+03	8.954000e+03	7.391000e+03	7.786000e+03	6.632000e+
16	Macao SAR, China	MAC	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	NaN	NaN	NaN	NaN	N
17	Macao SAR, China	MAC	GDP per capita (current US$)	NY.GDP.PCAP.CD	NaN	NaN	NaN	NaN	NaN	N
18	Macao SAR, China	MAC	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
19	Macao SAR, China	MAC	Population, total	SP.POP.TOTL	2.461950e+05	2.487390e+05	2.487670e+05	2.469470e+05	2.442840e+05	2.416280e+
20	Norway	NOR	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	2.437140e+05	2.503500e+05	2.701880e+05	2.658840e+05	2.649250e+
21	Norway	NOR	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	5.004700e+04	5.359800e+04	5.791400e+04	6.383800e+04	6.458200e+
22	Norway	NOR	GDP per capita (current US$)	NY.GDP.PCAP.CD	3.306219e+03	3.736349e+03	4.413576e+03	5.689589e+03	6.811527e+03	8.204452e+
23	Norway	NOR	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
24	Norway	NOR	Population, total	SP.POP.TOTL	3.875763e+06	3.903039e+06	3.933004e+06	3.960612e+06	3.985258e+06	4.007313e+
25	Qatar	QAT	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	3.649000e+03	4.476000e+03	5.443000e+03	6.301000e+03	7.139000e+
26	Qatar	QAT	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	0.000000e+00	NaN	NaN	NaN	N
27	Qatar	QAT	GDP per capita (current US$)	NY.GDP.PCAP.CD	2.755733e+03	3.246417e+03	3.909019e+03	5.581263e+03	1.562356e+04	1.528337e+
28	Qatar	QAT	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
29	Qatar	QAT	Population, total	SP.POP.TOTL	1.095140e+05	1.194240e+05	1.305340e+05	1.422410e+05	1.537040e+05	1.644130e+
30	Switzerland	CHE	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	NaN	NaN	NaN	NaN	N
31	Switzerland	CHE	Enrolment in tertiary	SE.TER.ENRL	NaN	5.142600e+04	5.359500e+04	5.653400e+04	6.032900e+04	6.258400e+

			education, all programme...							
32	Switzerland	CHE	GDP per capita (current US$)	NY.GDP.PCAP.CD	NaN	NaN	NaN	NaN	NaN	N
33	Switzerland	CHE	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
34	Switzerland	CHE	Population, total	SP.POP.TOTL	6.180877e+06	6.213399e+06	6.260956e+06	6.307347e+06	6.341405e+06	6.338632e+
35	United States	USA	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	2.059300e+07	2.116100e+07	NaN	2.159100e+07	2.165600e+
36	United States	USA	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	8.498117e+06	8.948645e+06	9.297787e+06	9.602123e+06	1.022373e+
37	United States	USA	GDP per capita (current US$)	NY.GDP.PCAP.CD	5.246884e+03	5.623444e+03	6.109926e+03	6.741332e+03	7.242441e+03	7.820065e+
38	United States	USA	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
39	United States	USA	Population, total	SP.POP.TOTL	2.050520e+08	2.076610e+08	2.098960e+08	2.119090e+08	2.138540e+08	2.159730e+

40 rows × 70 columns

In [366…

```
#Nous allons maintenant analyser les évolutions des pays les plus intéressants pour l'entreprise
#Pour cela on commence par trier les 8 pays au plus fort PIB par habitant

analyse_pays_hyp1 = data_par_pays[data_par_pays['Country Name'].isin(['Luxembourg','Switzerland',\
                                    'Macao SAR, China','Norway','Ireland','Iceland','Qatar','United Sta

analyse_pays_hyp1 = analyse_pays_hyp1[analyse_pays_hyp1['Indicator Code']\
                                      .isin(['SE.TER.ENRL', 'NY.GDP.PCAP.CD',\
                                             'IT.NET.USER.P2','SE.SEC.ENRL.GC','SP.POP.TOTL','PRJ.POP.AL

analyse_pays_hyp1 = analyse_pays_hyp1.reset_index(drop=True)

#On enregistre le tableau dans un doc excel
#fichier_excel = pd.ExcelWriter('Analyse_pays_hyp2.xlsx')
#analyse_pays_hyp2.to_excel(fichier_excel, "Sheet1")
#fichier_excel.save()

analyse_pays_hyp1
```

Out[366…

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	19
0	Iceland	ISL	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	1.807400e+04	1.882300e+04	1.938200e+04	1.992100e+04	1.982900e-
1	Iceland	ISL	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	1.706000e+03	1.970000e+03	2.267000e+03	2.429000e+03	2.695000e-
2	Iceland	ISL	GDP per capita (current US$)	NY.GDP.PCAP.CD	2.597387e+03	3.278649e+03	4.047619e+03	5.481730e+03	7.098028e+03	6.506867e-
3	Iceland	ISL	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
4	Iceland	ISL	Population, total	SP.POP.TOTL	2.044380e+05	2.060980e+05	2.091370e+05	2.123170e+05	2.152090e+05	2.179790e-
5	Iceland	ISL	Wittgenstein Projection: Population in thousan...	PRJ.POP.ALL.4.MF	NaN	NaN	NaN	NaN	NaN	N
6	Ireland	IRL	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	1.545750e+05	1.617960e+05	1.691760e+05	1.785570e+05	2.476090e-
7	Ireland	IRL	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	2.850100e+04	2.951700e+04	3.002000e+04	3.173700e+04	3.789700e-
8	Ireland	IRL	GDP per capita (current US$)	NY.GDP.PCAP.CD	1.488295e+03	1.705973e+03	2.082957e+03	2.427172e+03	2.519942e+03	2.976961e-
9	Ireland	IRL	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
10	Ireland	IRL	Population, total	SP.POP.TOTL	2.957250e+06	2.992050e+06	3.036850e+06	3.085950e+06	3.137500e+06	3.189550e-
11	Ireland	IRL	Wittgenstein Projection: Population in thousan...	PRJ.POP.ALL.4.MF	NaN	NaN	NaN	NaN	NaN	N
12	Luxembourg	LUX	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	8.689000e+03	8.924000e+03	8.685000e+03	8.425000e+03	8.213000e+03	1.501300e-
13	Luxembourg	LUX	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	3.630000e+02	3.660000e+02	4.850000e+02	4.580000e+02	5.220000e-
14	Luxembourg	LUX	GDP per capita (current US$)	NY.GDP.PCAP.CD	4.449540e+03	4.591748e+03	5.680130e+03	7.709729e+03	9.282808e+03	9.008028e-
15	Luxembourg	LUX	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
16	Luxembourg	LUX	Population, total	SP.POP.TOTL	3.391710e+05	3.424210e+05	3.466000e+05	3.504500e+05	3.550500e+05	3.589500e-
17	Luxembourg	LUX	Wittgenstein Projection: Population in thousan...	PRJ.POP.ALL.4.MF	NaN	NaN	NaN	NaN	NaN	N
18	Macao SAR, China	MAC	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	8.960000e+03	8.954000e+03	7.391000e+03	7.786000e+03	6.632000e-
19	Macao SAR, China	MAC	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	NaN	NaN	NaN	NaN	N
20	Macao SAR, China	MAC	GDP per capita (current US$)	NY.GDP.PCAP.CD	NaN	NaN	NaN	NaN	NaN	N
21	Macao SAR, China	MAC	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
22	Macao SAR, China	MAC	Population, total	SP.POP.TOTL	2.461950e+05	2.487390e+05	2.487670e+05	2.469470e+05	2.442840e+05	2.416280e-
23	Macao SAR, China	MAC	Wittgenstein Projection: Population in thousan...	PRJ.POP.ALL.4.MF	NaN	NaN	NaN	NaN	NaN	N
24	Norway	NOR	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	2.437140e+05	2.503500e+05	2.701880e+05	2.658840e+05	2.649250e-
25	Norway	NOR	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	5.004700e+04	5.359800e+04	5.791400e+04	6.383800e+04	6.458200e-
26	Norway	NOR	GDP per capita (current US$)	NY.GDP.PCAP.CD	3.306219e+03	3.736349e+03	4.413576e+03	5.689589e+03	6.811527e+03	8.204452e-
27	Norway	NOR	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
28	Norway	NOR	Population, total	SP.POP.TOTL	3.875763e+06	3.903039e+06	3.933004e+06	3.960612e+06	3.985258e+06	4.007313e-
29	Norway	NOR	Wittgenstein Projection: Population in thousan...	PRJ.POP.ALL.4.MF	NaN	NaN	NaN	NaN	NaN	N
30	Qatar	QAT	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	3.649000e+03	4.476000e+03	5.443000e+03	6.301000e+03	7.139000e-
31	Qatar	QAT	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	0.000000e+00	NaN	NaN	NaN	N
32	Qatar	QAT	GDP per capita (current US$)	NY.GDP.PCAP.CD	2.755733e+03	3.246417e+03	3.909019e+03	5.581263e+03	1.562356e+04	1.528337e-
33	Qatar	QAT	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
34	Qatar	QAT	Population, total	SP.POP.TOTL	1.095140e+05	1.194240e+05	1.305340e+05	1.422410e+05	1.537040e+05	1.644130e-
35	Qatar	QAT	Wittgenstein Projection: Population in thousan...	PRJ.POP.ALL.4.MF	NaN	NaN	NaN	NaN	NaN	N
36	Switzerland	CHE	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	NaN	NaN	NaN	NaN	N
37	Switzerland	CHE	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	5.142600e+04	5.359500e+04	5.653400e+04	6.032900e+04	6.258400e-
38	Switzerland	CHE	GDP per capita (current US$)	NY.GDP.PCAP.CD	NaN	NaN	NaN	NaN	NaN	N
39	Switzerland	CHE	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
40	Switzerland	CHE	Population, total	SP.POP.TOTL	6.180877e+06	6.213399e+06	6.260956e+06	6.307347e+06	6.341405e+06	6.338632e-
41	Switzerland	CHE	Wittgenstein Projection: Population in thousan...	PRJ.POP.ALL.4.MF	NaN	NaN	NaN	NaN	NaN	N
42	United States	USA	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	2.059300e+07	2.116100e+07	NaN	2.159100e+07	2.165600e-
43	United States	USA	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	8.498117e+06	8.948645e+06	9.297787e+06	9.602123e+06	1.022373e-
44	United States	USA	GDP per capita (current US$)	NY.GDP.PCAP.CD	5.246884e+03	5.623444e+03	6.109926e+03	6.741332e+03	7.242441e+03	7.820065e-
45	United States	USA	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	N
46	United States	USA	Population, total	SP.POP.TOTL	2.050520e+08	2.076610e+08	2.098960e+08	2.119090e+08	2.138540e+08	2.159730e-
47	United States	USA	Wittgenstein Projection: Population in thousan...	PRJ.POP.ALL.4.MF	NaN	NaN	NaN	NaN	NaN	N

48 rows × 70 columns

In [367…

```
plt.figure(1,figsize=(15, 10))

ax1 = plt.subplot(1, 2, 1)

data = analyse_pays_hyp1.loc[analyse_pays_hyp1['Indicator Code'] == 'IT.NET.USER.P2']
annees = ['2010','2011','2012','2013','2014','2015','2016']

#On trace les courbes de chaque pays
for i in data.itertuples():

     ax1.plot(annees, data.loc[i[0],'2010':'2016'],\
              label=data.loc[i[0],'Country Name'], marker = 'o')

#On affiche la grille

ax1.grid(True)
#On paramètre le graphique et on l'affiche
ax1.set(title="Evolution accès internet")

ax1.legend(loc = 'upper left', prop = {'size': 10})
#ax1.text(5.9, 77, '76%', fontsize = 10, color = 'black')
#ax1.text(5.9, 54.5, '53%', fontsize = 10, color = 'black')
#ax1.text(5.7, 30.5, '29.5%', fontsize = 10, color = 'black')

ax2 = plt.subplot(2, 2, 2)

#On construit tout d'abord les données à tracer
#On appelle la fonction qui nous trie le dataset de base en fonction d'un indicateur
data = filtre_indicateur(analyse_pays_hyp1,'NY.GDP.PCAP.CD')

#Ensuite on trie le résultat par ordre décroissant suivant une colonne donnée
#Ici 2016, est la dernière année contenant des données
data = data.sort_values(by = '2016', ascending = False)

#Le tri précédent ayant aussi modifié l'ordre des lignes, on remet l'index du dataframe à 0
data = data.reset_index(drop = True)

#Enfin, on supprime les lignes contenant des valeurs nulles
data = list(data['2016'].dropna())

ax2.boxplot(data,whis=[5,95])

#On paramètre le graphique et on l'affiche
ax2.set(ylim=[50000,110000],title="Analyse PIB par habitant en 2016", ylabel='Dollars ($)')

ax2.text(1.1, 66500, 'Médiane : 5219$', fontsize = 10, color = 'coral')
ax2.text(1.1, 58000, '5% de la population', fontsize = 10, color = 'black')
ax2.text(1.1, 79500, "95% de l'échantillon", fontsize = 10, color = 'black')

#ax2.text(0.52, 58000, 'United States : : 57638.2$', fontsize = 10, color = 'coral')
#ax2.text(0.52, 55000, 'China : 8123.2$', fontsize = 10, color = 'lightskyblue')
#ax2.text(0.52, 52000, 'India : 1710$', fontsize = 10, color = 'lightslategray')

ax3 = plt.subplot(2, 2, 4)


data = analyse_pays_hyp1.loc[analyse_pays_hyp1['Indicator Code'] == 'SP.POP.TOTL']
data = data['2016']
data = data.reset_index(drop=True)
#On enlève les Etats Unis qui sont une valeur abérantes pour le camembert.
#Ils représentent 95% de l'échantillon,du coup on ne voit pas les autres pays dans le graphique.
data = data.drop(7,axis=0)

labels = analyse_pays_hyp1['Country Name'].unique()
labels = np.delete(labels, (7), axis=0)

explode = (0.1, 0.1, 0.1, 0.1, 0.1, 0.1, 0.1)

ax3.set(title="Population totale en 2016")
ax3.pie(data, explode=explode, shadow=True, startangle=90, labels = labels)
#ax3.legend(bbox_to_anchor = (1, 1), loc = 'best', labels=labels)
```

Out[367…

```
([<matplotlib.patches.Wedge at 0x2a83c2d9d30>,
  <matplotlib.patches.Wedge at 0x2a841af2278>,
  <matplotlib.patches.Wedge at 0x2a841af2128>,
  <matplotlib.patches.Wedge at 0x2a83dfdb780>,
  <matplotlib.patches.Wedge at 0x2a83dfdb748>,
  <matplotlib.patches.Wedge at 0x2a8386941d0>,
  <matplotlib.patches.Wedge at 0x2a8386942e8>],
 [Text(-0.0560405909330616, 1.1986907241519278, 'Iceland'),
  Text(-0.8271903923758984, 0.8693423116132145, 'Ireland'),
  Text(-1.197721309066874, 0.07391661387762463, 'Luxembourg'),
  Text(-1.193340028928926, -0.1262520310956431, 'Macao SAR, China'),
  Text(-0.7247308457216247, -0.9564335843432198, 'Norway'),
  Text(0.5134368899783257, -1.0846117093270684, 'Qatar'),
  Text(1.104968489777341, 0.46802204712938755, 'Switzerland')])
```

In [389…

```
#On crée un graphique pour visualiser le nombre d'inscriptions au secondaire et supérieur

#On dimensionne le graphique
fig, ax = plt.subplots(figsize=(15, 7))

name = analyse_pays_hyp1['Country Name'].unique()

#On construit les barres pour le secondaire
inscriptions_sec = analyse_pays_hyp1.loc[analyse_pays_hyp1['Indicator Code'] == 'SE.SEC.ENRL.GC']
inscriptions_sec = inscriptions_sec['2015']
#On enlève les Etats Unis qui sont une valeur abérantes pour l'échantillon
inscriptions_sec = inscriptions_sec.reset_index(drop=True)
inscriptions_sec = inscriptions_sec.drop(7,axis=0)

inscriptions_sup = analyse_pays_hyp1.loc[analyse_pays_hyp1['Indicator Code'] == 'SE.TER.ENRL']
inscriptions_sup = inscriptions_sup['2015']
#On enlève les Etats Unis qui sont une valeur abérantes pour l'échantillon
inscriptions_sup = inscriptions_sup.reset_index(drop=True)
inscriptions_sup = inscriptions_sup.drop(7,axis=0)

barWidth = 0.4
position_sec = range(len(inscriptions_sec))
position_sup = [x + barWidth for x in position_sec]

bar1 = ax.bar(position_sec, inscriptions_sec, width = barWidth, color = 'lightskyblue')
bar2 = ax.bar(position_sup, inscriptions_sup, width = barWidth, color = 'lightslategray')

plt.xticks([r + barWidth / 2 for r in range(len(inscriptions_sec))], name)

plt.title("Nbr d'inscriptions en 2015", size=15)
ax.legend(['Inscriptions secondaire','Inscriptions supérieur'], loc = "upper center")
ax.text(2.6, 350000, 'Enseignement sup United States = 19531728', fontsize = 10, color = 'black')

def autolabel(rects, xpos='center'):
    """
    Attach a text label above each bar in *rects*, displaying its height.

    *xpos* indicates which side to place the text w.r.t. the center of
    the bar. It can be one of the following {'center', 'right', 'left'}.
    """

    ha = {'center': 'center', 'right': 'left', 'left': 'right'}
    offset = {'center': 0, 'right': 1, 'left': -1}

    for rect in rects:
        height = rect.get_height()
        ax.annotate('{}'.format(height),
                    xy=(rect.get_x() + rect.get_width() / 2, height),
                    xytext=(offset[xpos]*3, 3),  # use 3 points offset
                    textcoords="offset points",  # in both directions
                    ha=ha[xpos], va='bottom')


autolabel(bar1, "center")
autolabel(bar2, "center")
```

In [390…

```
data = analyse_pays_hyp1.loc[analyse_pays_hyp1['Indicator Code'] == 'PRJ.POP.ALL.4.MF']
#On enlève les Etats Unis qui sont une valeur abérantes pour le camembert.
#Ils représentent 95% de l'échantillon,du coup on ne voit pas les autres pays dans le graphique.
data = data.reset_index(drop=True)
data['2050']
```

Out[390…

```
0       205.37
1      3453.16
2       278.08
3       350.75
4      2765.30
5       893.25
6      2727.07
7    145446.92
Name: 2050, dtype: float64
```

In [394…

```
#On trace l'évolution du taux d'accès à internet de chaque pays

data = analyse_pays_hyp1.loc[analyse_pays_hyp1['Indicator Code'] == 'PRJ.POP.ALL.4.MF']
#On enlève les Etats Unis qui sont une valeur abérantes pour le camembert.
#Ils représentent 95% de l'échantillon,du coup on ne voit pas les autres pays dans le graphique.
data = data.reset_index(drop=True)
data = data.drop(7,axis=0)

annees = ['2015','2016','2017','2020','2025','2030','2035','2040','2045','2050']

fig, ax = plt.subplots(figsize=(10, 10))

#On trace les courbes de chaque pays
for i in data.itertuples():

    ax.plot(annees, data.loc[i[0],'2015':'2050'],\
            label=data.loc[i[0],'Country Name'],marker='o')

ax.legend(loc = 'upper left', prop = {'size': 10})
ax.text(9.6, 3500, '3453', fontsize = 10, color = 'black')
ax.text(9.6, 2800, '2765', fontsize = 10, color = 'black')
ax.text(9.6, 2700, '2727', fontsize = 10, color = 'black')
ax.text(9.6, 900, '893', fontsize = 10, color = 'black')
ax.text(9.6, 350, '350', fontsize = 10, color = 'black')
ax.text(9.6, 250, '278', fontsize = 10, color = 'black')
ax.text(9.6, 150, '205', fontsize = 10, color = 'black')
ax.text(-0.3, 2700, 'United States en 2050 = 145447', fontsize = 10, color = 'black')

#On paramètre le graphique et on l'affiche
ax.set(title="Perspective de réussite en enseignement supérieur")

#On enregistre le graphique
plt.savefig('evol_pop_ens_sup.png', transparent = True, dpi = 700)

plt.show()
```

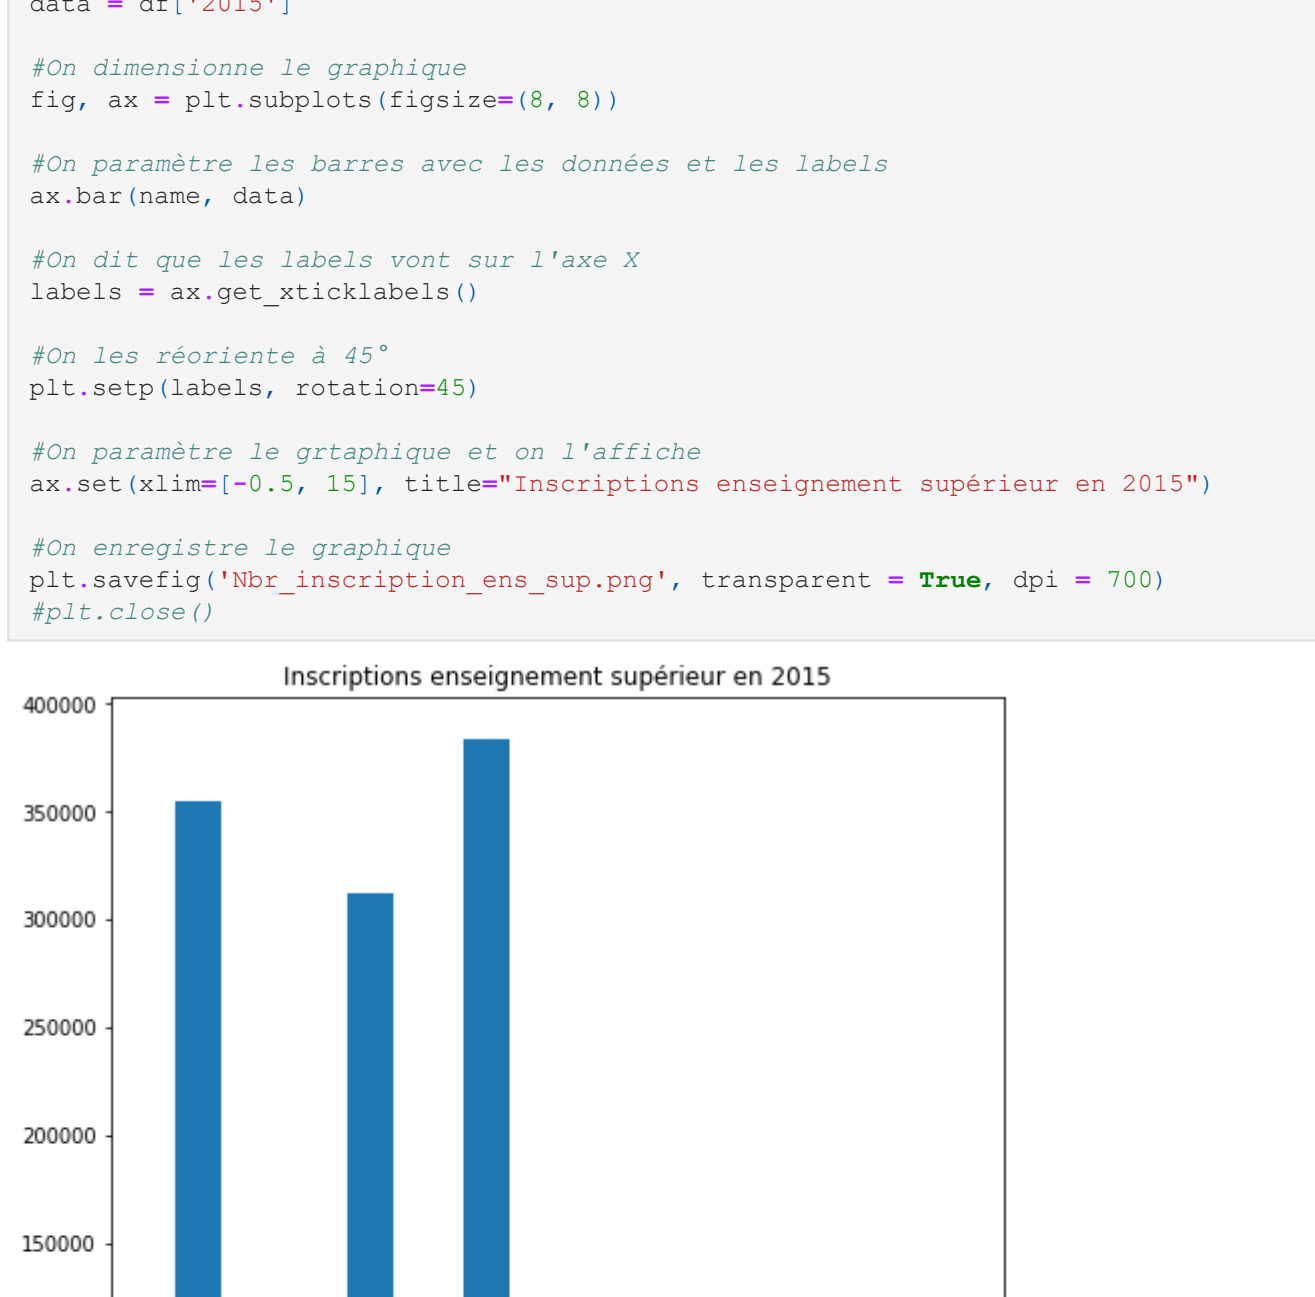

In [52]:

```
#On fait une analyse des 8 premiers pays des inscriptions en enseignement secondaire

df = analyse_PIB.loc[analyse_PIB['Indicator Code'] == 'SE.SEC.ENRL.GC']

name = df['Country Name']
data = df['2015']

#On dimensionne le graphique
fig, ax = plt.subplots(figsize=(8, 8))

#On paramètre les barres avec les données et les labels
ax.bar(name, data)

#On dit que les labels vont sur l'axe X
labels = ax.get_xticklabels()

#On les réoriente à 45°
plt.setp(labels, rotation=45)

#On paramètre le grtaphique et on l'affiche
ax.set(xlim=[-0.5, 15], title="Inscriptions enseignement supérieur en 2015")

#On enregistre le graphique
plt.savefig('Nbr_inscription_ens_sup.png', transparent = True, dpi = 700)
#plt.close()
```

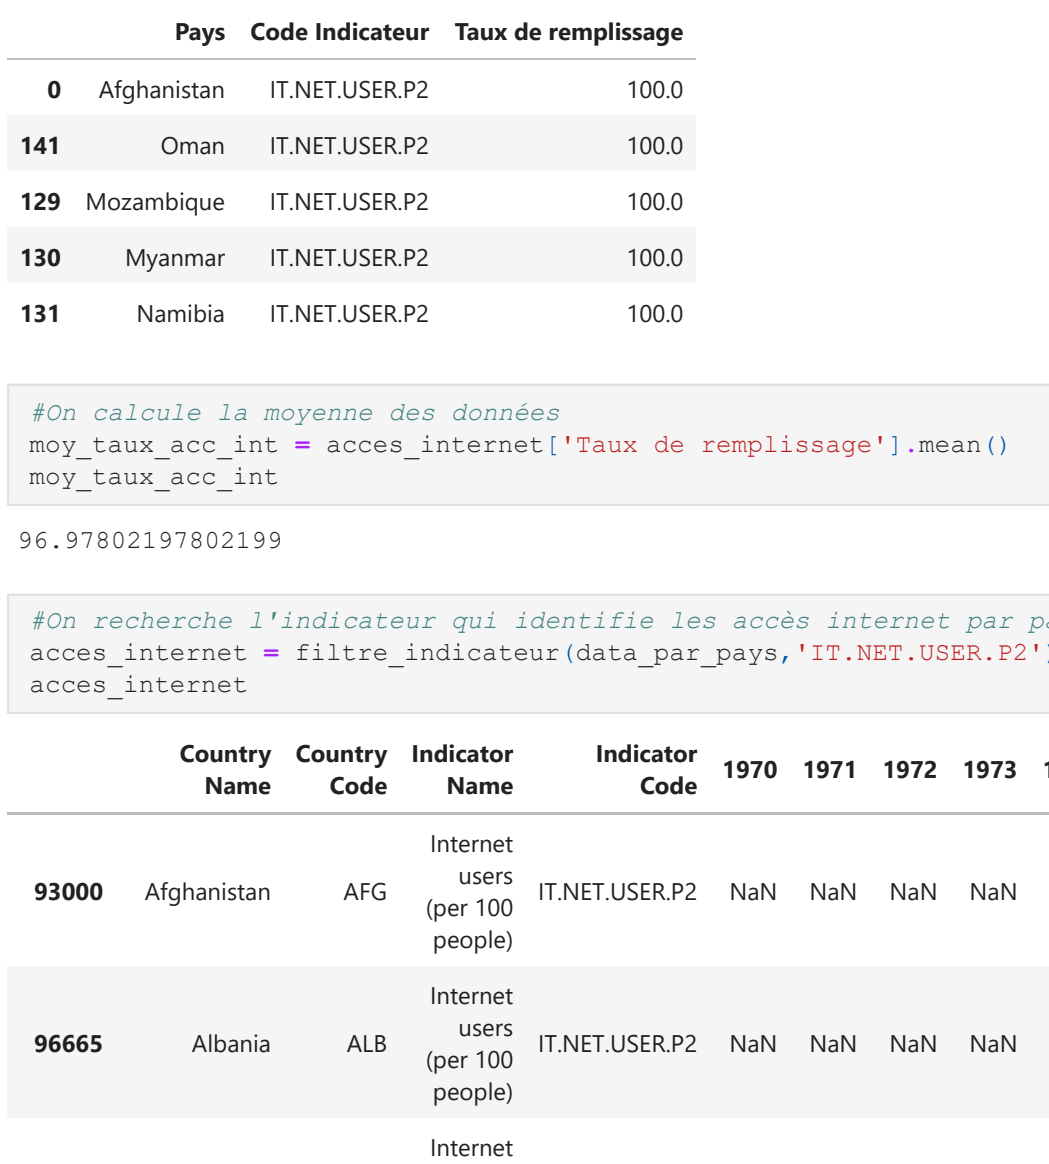

In [54]:

```
#CETTE PARTIE EST UNE ANALYSE DES TAUX D'ACCES A INTERNET PAR PAYS

#On recherche l'indicateur qui contient le taux d'accès à internet
#Pour analyser le taux de remplissage des données
acces_internet = recherche_indicateur(data_par_pays,'IT.NET.USER.P2')
acces_internet = acces_internet.sort_values(by = 'Taux de remplissage', ascending = False)
acces_internet.head()
```

Out[54]:

	Pays	Code Indicateur	Taux de remplissage
0	Afghanistan	IT.NET.USER.P2	100.0
141	Oman	IT.NET.USER.P2	100.0
129	Mozambique	IT.NET.USER.P2	100.0
130	Myanmar	IT.NET.USER.P2	100.0
131	Namibia	IT.NET.USER.P2	100.0

In [55]:

```
#On calcule la moyenne des données
moy_taux_acc_int = acces_internet['Taux de remplissage'].mean()
moy_taux_acc_int
```

Out[55]: 96.97802197802199

In [56]:

```
#On recherche l'indicateur qui identifie les accès internet par pays
acces_internet = filtre_indicateur(data_par_pays,'IT.NET.USER.P2')
acces_internet
```

Out[56]:

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	1975	...	2060	2065	2070	2075	2080	2085
93000	Afghanistan	AFG	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
96665	Albania	ALB	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
100330	Algeria	DZA	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
103995	American Samoa	ASM	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
107660	Andorra	AND	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
111325	Angola	AGO	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
114990	Antigua and Barbuda	ATG	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
118655	Argentina	ARG	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
122320	Armenia	ARM	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
125985	Aruba	ABW	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
129650	Australia	AUS	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
133315	Austria	AUT	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
136980	Azerbaijan	AZE	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
140645	Bahamas, The	BHS	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
144310	Bahrain	BHR	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
147975	Bangladesh	BGD	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
151640	Barbados	BRB	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
155305	Belarus	BLR	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
158970	Belgium	BEL	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
162635	Belize	BLZ	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
166300	Benin	BEN	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
169965	Bermuda	BMU	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
173630	Bhutan	BTN	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
177295	Bolivia	BOL	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
180960	Bosnia and Herzegovina	BIH	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
184625	Botswana	BWA	Internet users (per 100 people)	IT.NET.USER.P2	0.0	NaN	NaN	NaN	NaN	0.0	...	NaN	NaN	NaN	NaN	NaN	NaN
188290	Brazil	BRA	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
195620	Brunei Darussalam	BRN	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
199285	Bulgaria	BGR	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
202950	Burkina Faso	BFA	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
778355	Sweden	SWE	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
782020	Switzerland	CHE	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
785685	Syrian Arab Republic	SYR	Internet users (per 100 people)	IT.NET.USER.P2	0.0	NaN	NaN	NaN	NaN	0.0	...	NaN	NaN	NaN	NaN	NaN	NaN
789350	Tajikistan	TJK	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
793015	Tanzania	TZA	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
796680	Thailand	THA	Internet users (per 100 people)	IT.NET.USER.P2	0.0	NaN	NaN	NaN	NaN	0.0	...	NaN	NaN	NaN	NaN	NaN	NaN
800345	Timor-Leste	TLS	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
804010	Togo	TGO	Internet users (per 100 people)	IT.NET.USER.P2	0.0	NaN	NaN	NaN	NaN	0.0	...	NaN	NaN	NaN	NaN	NaN	NaN
807675	Tonga	TON	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
811340	Trinidad and Tobago	TTO	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
815005	Tunisia	TUN	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
818670	Turkey	TUR	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
822335	Turkmenistan	TKM	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
826000	Turks and Caicos Islands	TCA	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
829665	Tuvalu	TUV	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
833330	Uganda	UGA	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
836995	Ukraine	UKR	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
840660	United Arab Emirates	ARE	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
844325	United Kingdom	GBR	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
847990	United States	USA	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
851655	Uruguay	URY	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
855320	Uzbekistan	UZB	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
858985	Vanuatu	VUT	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN

862650	Venezuela, RB	VEN	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
866315	Vietnam	VNM	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
869980	Virgin Islands (U.S.)	VIR	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
873645	West Bank and Gaza	PSE	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
877310	Yemen, Rep.	YEM	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
880975	Zambia	ZMB	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN
884640	Zimbabwe	ZWE	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN

208 rows × 70 columns

In [57]:
```
#On calcule la moyenne de taux d'accès à internet pour l'année 2016 qui est l'année avec le plus de données
moyenne_internet = acces_internet['2016'].mean()
moyenne_internet
```
Out[57]: 51.41452271657214

In [58]:
```
#Une fois que la moyenne a été calculée, nous pouvons rechercher les pays au-dessus de cette moyenne
pays_sup = acces_internet[acces_internet['2016'] > moyenne_internet]
pays_sup.shape
```
Out[58]: (105, 70)

In [59]:
```
#et ceux qui sont en-dessous
pays_inf = acces_internet[acces_internet['2016'] < moyenne_internet]
pays_inf.shape
```
Out[59]: (96, 70)

In [69]:
```
#On trace un graphique pour illustrer l'état des lieu des moyennes

fig, ax = plt.subplots(figsize=(6, 6))

labels = 'Pays au dessus de la moyenne', 'Pays en dessous de la moyenne'
sizes = [pays_sup.shape[0], pays_inf.shape[0]]
explode = (0.1, 0.1,)
colors = ['lightskyblue', 'lightslategray',]

plt.title("Moyenne d'accès à internet = 51.4%")
plt.pie(sizes, explode=explode, autopct='%1.1f%%', colors=colors,shadow=True, startangle=90)
plt.legend(bbox_to_anchor = (1, 1), loc = 'best', labels=labels)

#plt.axis('equal')

plt.rcParams['svg.fonttype'] = 'none'
plt.savefig('Moyenne_internet.png',transparent=True)
plt.show()
```

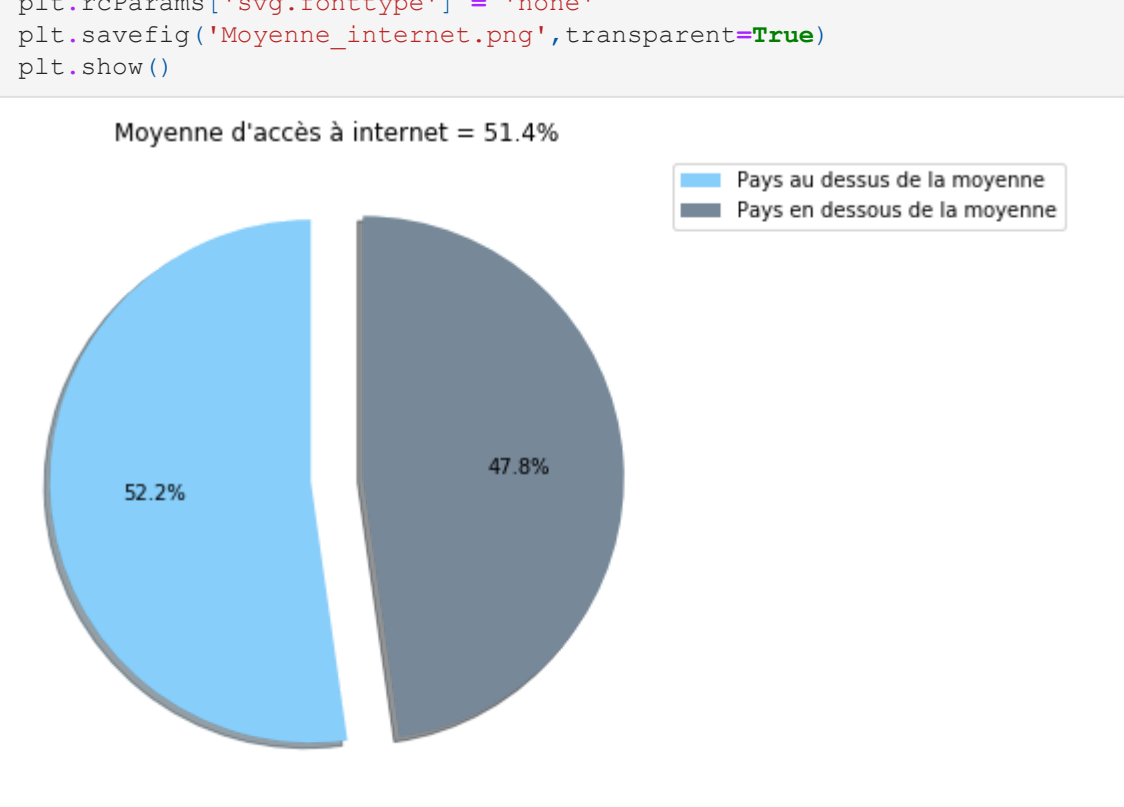

In [70]:
```
#On classe les pays par ordre croissant d'accès à internet
acces_internet = acces_internet.sort_values(by = '2016', ascending = False)
acces_internet.head(1)
```
Out[70]:

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	1975	...	2060	2065	2070	2075	2080	2085	2090
411855	Iceland	ISL	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN

1 rows × 70 columns

In [72]:
```
#On crée un graphique en barres verticales avec la moyenne pour visualiser quels sont pays au-dessus et en-d
name = acces_internet['Country Name']
data = acces_internet['2016']

#On dimensionne le graphique
fig, ax = plt.subplots(figsize=(35, 15))

#On paramètre les barres avec les données et les labels
ax.bar(name, data)

#On paramètre la ligne de la moyenne
ax.axhline(moyenne_internet, ls='--', color='r')

#On dit que les labels vont sur l'axe X
labels = ax.get_xticklabels()
#On les réoriente à 45°
plt.setp(labels, rotation=45)

#On paramètre le grtaphique et on l'affiche
ax.set(xlim=[0, acces_internet.shape[0]], xlabel='Pays', ylabel="Taux d'accès à internet (Pour 100 personnes
       title="Taux d'accès à internet")

#On enregistre le graphique
plt.savefig('Acces_internet.png', transparent = True, dpi = 700)
#plt.close()
```

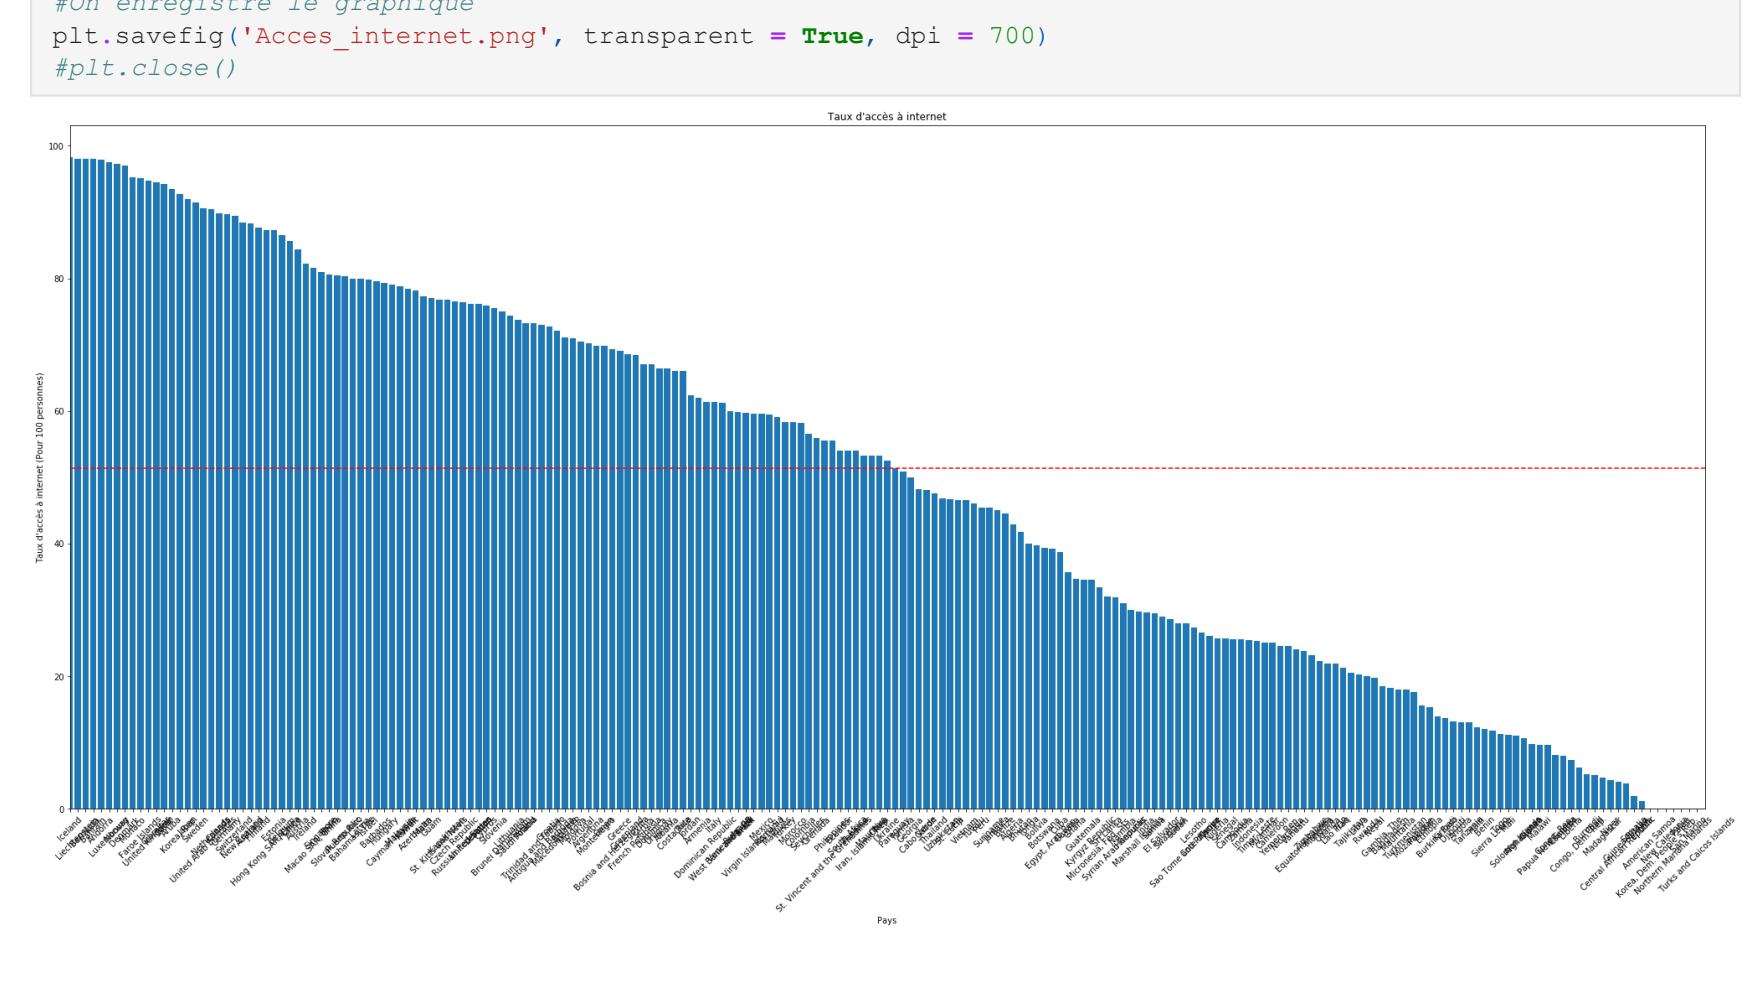

Nous allons rechercher tous les indicateurs ayant un rapport avec l'enseignement secondaire.

Le but est de rechercher les indicateurs avec le plus de remplissage de données pour faire une analyse la plus juste possible.

In [398…
```
#Nous allons créer un tableau contenant tous les indicateurs se rapportant au secondaire avec le taux de
#remplissage de données pour chaque indicateur.
indicateurs_secondaires_total = pd.DataFrame(columns=['Pays','Code Indicateur','Taux de remplissage'])

#Nous bouclons sur la liste des régions
for i in data_par_pays.itertuples():

    if 'SE.SEC.' in data_par_pays.loc[i[0],'Indicator Code']:

        #On analyse les données sur 8 colonnes de 2010 à 2017
        nbr_donnees_totales = 8
        nbr_donnees_nulles = data_par_pays.loc[i[0],'2010':'2017'].isnull().sum().sum()
        taux_remplissage_indicateur = 100-(nbr_donnees_nulles / nbr_donnees_totales)*100

        #On incrémente ensuite le tableau de sortie
        indicateurs_secondaires_total = \
            indicateurs_secondaires_total.append({'Pays':data_par_pays.loc[i[0],'Country Name'], \
                                                  'Code Indicateur':data_par_pays.loc[i[0],'Indicator Code'], \
                                                  'Taux de remplissage':taux_remplissage_indicateur}, ignore_index

indicateurs_secondaires_total.head()
```
Out[398…

	Pays	Code Indicateur	Taux de remplissage
0	Afghanistan	SE.SEC.PROG.ZS	0.0
1	Afghanistan	SE.SEC.PROG.FE.ZS	0.0
2	Afghanistan	SE.SEC.PROG.MA.ZS	0.0
3	Afghanistan	SE.SEC.ENRL	75.0
4	Afghanistan	SE.SEC.ENRL.FE	75.0

In [402…
```
indic_sec_unique = indicateurs_secondaires_total['Code Indicateur'].unique().tolist()
len(indic_sec_unique)
```
Out[402… 42

In [74]:
```
#Calcul du taux de remplissage par indicateur
indic_sec_unique = indicateurs_secondaires_total['Code Indicateur'].unique().tolist()

tab_moy_indic_sec = pd.DataFrame(columns=['Code Indicateur', 'Moyenne'])

for i in range(len(indic_sec_unique)):
    masque = indicateurs_secondaires_total[indicateurs_secondaires_total['Code Indicateur'] == \
                                           indic_sec_unique[i]]

    moyenne = masque['Taux de remplissage'].mean()

    #On incrémente ensuite le tableau de sortie
    tab_moy_indic_sec = \
        tab_moy_indic_sec.append({'Code Indicateur':indic_sec_unique[i], \
                                  'Moyenne':moyenne}, ignore_index=True)

tab_moy_indic_sec = tab_moy_indic_sec.sort_values(by = 'Moyenne', ascending = False)
tab_moy_indic_sec.head()
```
Out[74]:

	Code Indicateur	Moyenne
37	SE.SEC.DURS	85.548780
38	SE.SEC.DURS.UP	83.911483
36	SE.SEC.DURS.LO	83.911483
24	SE.SEC.AGES	83.911483
9	SE.SEC.ENRR.LO	58.035714

In [75]:
```
moyenne_indic_sec = tab_moy_indic_sec['Moyenne'].mean()
moyenne_indic_sec
```
Out[75]: 50.410355613487866

In [76]:
```
#On crée un graphique en barres verticales avec la moyenne pour visualiser quels sont pays au-dessus et en-d
name = tab_moy_indic_sec['Code Indicateur']
data = tab_moy_indic_sec['Moyenne']

#On dimensionne le graphique
fig, ax = plt.subplots(figsize=(15, 8))

#On paramètre les barres avec les données et les labels
ax.bar(name, data)

#On paramètre la ligne de la moyenne
ax.axhline(moyenne_indic_sec, ls='--', color='r')

#On dit que les labels vont sur l'axe X
labels = ax.get_xticklabels()

#On les réoriente à 85°
plt.setp(labels, rotation=85)

#On modifie la taille de police des labels
plt.xticks(fontsize=8)

#On paramètre le grtaphique et on l'affiche
ax.set(xlim=[-1, tab_moy_indic_sec.shape[0]], xlabel='Indicateurs', ylabel='% de données',
       title="Taux de données par indicateur")

#On enregistre le graphique
plt.savefig('Indic_ens_sec.png', transparent = True, dpi = 700)
```

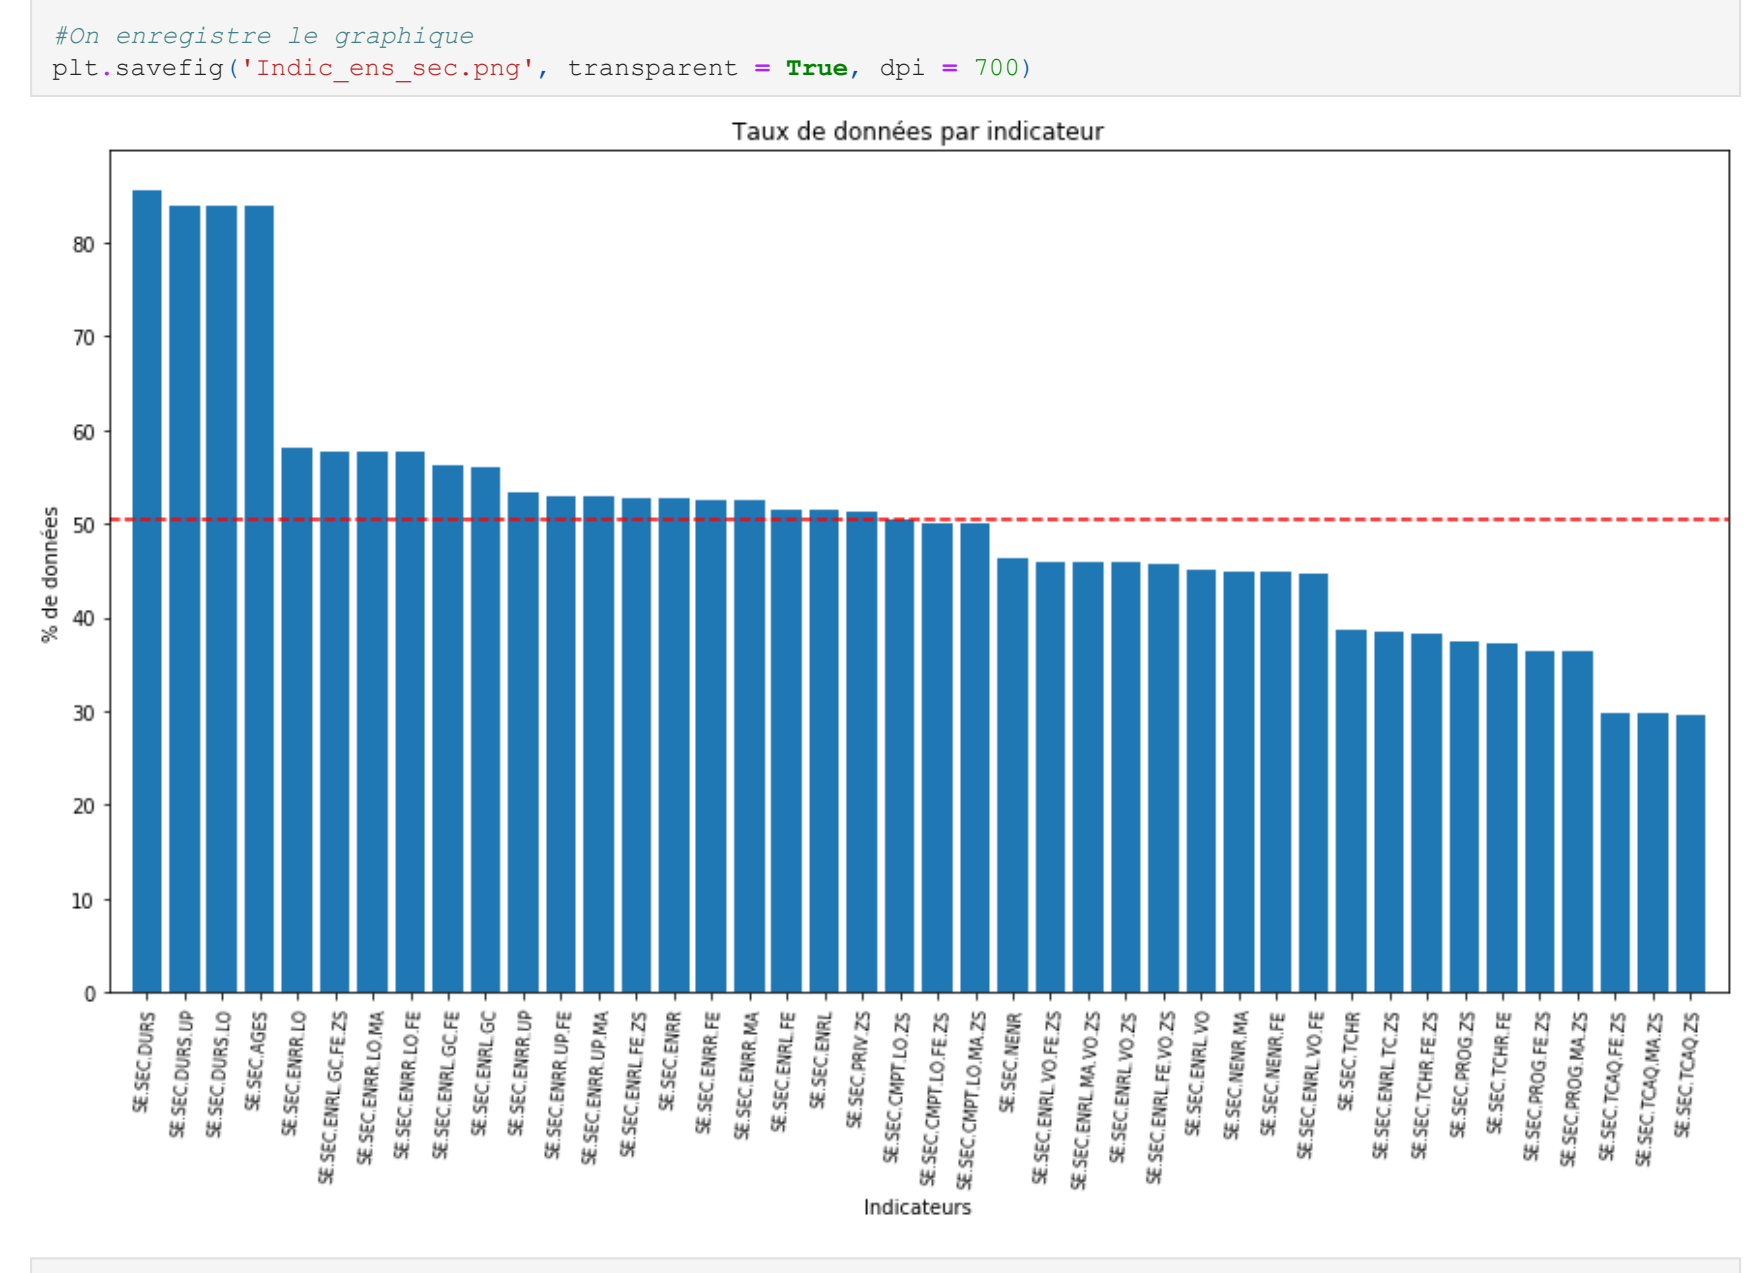

In [77]:
```
#On recherche quels sont les noms des indicateurs les plus remplis
nom_indic_sec = data_par_pays[data_par_pays['Indicator Code'].isin(['SE.SEC.DURS', 'SE.SEC.DURS.UP',\
                                                                    'SE.SEC.DURS.LO','SE.SEC.AGES'])]
nom_indic_sec = data_par_pays.loc[:, 'Indicator Code']
```
In [78]:
```
len(indic_sec_unique)
```
Out[78]: 42

On va analyser maintenant les pays avec un indicateur important pour l'analyse :

Le plus fort taux d'inscription au secondaire : SE.SEC.ENRL.GC

Attention cependant, le remplissage de cet indicateur s'arrête en 2015!

In [79]:
```
#On recherche l'indicateur
inscription_secondaire = data_par_pays.loc[data_par_pays['Indicator Code'] ==  'SE.SEC.ENRL.GC',:]
inscription_secondaire.head(1)
```
Out[79]:

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	1975	...	2060	2065	2070
92822	Afghanistan	AFG	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	107609.0	127162.0	146988.0	159464.0	167397.0	179763.0	...	NaN	NaN	NaN

1 rows × 70 columns

In [80]:
```
#Nous allons analyser l'évolution du taux de données pour cet indicateur

#Nous créons un nouveau dataframe dans lequel seront stockés les résultats
tab_taux = pd.DataFrame(columns=['Année','taux de données (%)'])

#Nous bouclons sur les colonnes correspondant aux années
j=2010

while j <= 2017:

    nbr_donnees_totales = inscription_secondaire.shape[0]

    nbr_donnees_nulles = inscription_secondaire.loc[:,str(j)].isnull().sum().sum()

    taux_remplissage_secondaire = 100-(nbr_donnees_nulles / nbr_donnees_totales)*100

    tab_taux = \
        tab_taux.append({'Année':j,'taux de données (%)':taux_remplissage_secondaire}, ignore_index=True)
    j+=1

print(tab_taux)
```
```
    Année  taux de données (%)
0  2010.0            74.407583
1  2011.0            77.251185
2  2012.0            77.251185
3  2013.0            73.933649
4  2014.0            73.933649
5  2015.0            66.350711
6  2016.0             5.687204
7  2017.0             0.000000
```

In [81]:
```
#On tri dans l'ordre décroissant les pays avec le plus d'inscriptions
inscription_secondaire= inscription_secondaire.sort_values(by = '2015', ascending = False)
inscription_secondaire.head()
```
Out[81]:

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	1975	...	2060
415342	India	IND	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	20924504.0	21736480.0	22598960.0	NaN	24263480.0	...	NaN
243087	China	CHN	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	20214900.0	26418500.0	31276100.0	35824400.0	34464300.0	36503600.0	...	NaN
188112	Brazil	BRA	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	3055652.0	3992048.0	4943407.0	5270588.0	6958947.0	7560303.0	...	NaN
419007	Indonesia	IDN	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	1815645.0	1955806.0	2102558.0	2246893.0	2400044.0	2709953.0	...	NaN
147797	Bangladesh	BGD	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	NaN	1930345.0	2255750.0	2366148.0	2442842.0	...	NaN

5 rows × 70 columns

In [82]:
```
#On calcule la moyenne d'inscriptions au secondaire pour l'année 2015 qui est l'année avec le plus de donnée
moyenne_secondaire = inscription_secondaire['2015'].mean()
moyenne_secondaire
```
Out[82]: 2930014.063169643

In [84]:
```
#Une fois que la moyenne a été calculée, nous pouvons rechercher les pays au-dessus de cette moyenne
pays_sup_secondaire = inscription_secondaire[inscription_secondaire['2015'] > moyenne_secondaire]
pays_sup_secondaire.shape
```
Out[84]: (20, 70)

In [85]:
```
#et ceux qui sont en-dessous
pays_inf_secondaire = inscription_secondaire[inscription_secondaire['2015'] < moyenne_secondaire]
pays_inf_secondaire.shape
```
Out[85]: (120, 70)

In [86]:
```
#On crée un graphique en barres verticales avec la moyenne pour visualiser quels sont pays au-dessus et en-d

#On ne va analyser que les 15 premiers pays
#On reset l'index avant. Pour que l'ordre des pays soit concordant dans le graphique.
inscription_secondaire = inscription_secondaire.reset_index(drop=True)

name = inscription_secondaire['Country Name']
data = inscription_secondaire['2015']

#On dimensionne le graphique
fig, ax = plt.subplots(figsize=(5, 7))

#On paramètre les barres avec les données et les labels
ax.bar(name, data, width=0.8)

#On paramètre la ligne de la moyenne
ax.axhline(moyenne_secondaire, ls='--', color='r')

#On dit que les labels vont sur l'axe X
labels = ax.get_xticklabels()

#On les réoriente à 45°
plt.setp(labels, rotation=45)

#On paramètre le graphique et on l'affiche
ax.set(xlim=[-1, 15],  ylabel='Pays',
       title="Nombre d'inscriptions au secondaire")

#On enregistre le graphique
plt.savefig('inscriptions_secondaire.png', transparent = True, dpi = 700)
#plt.close()
```

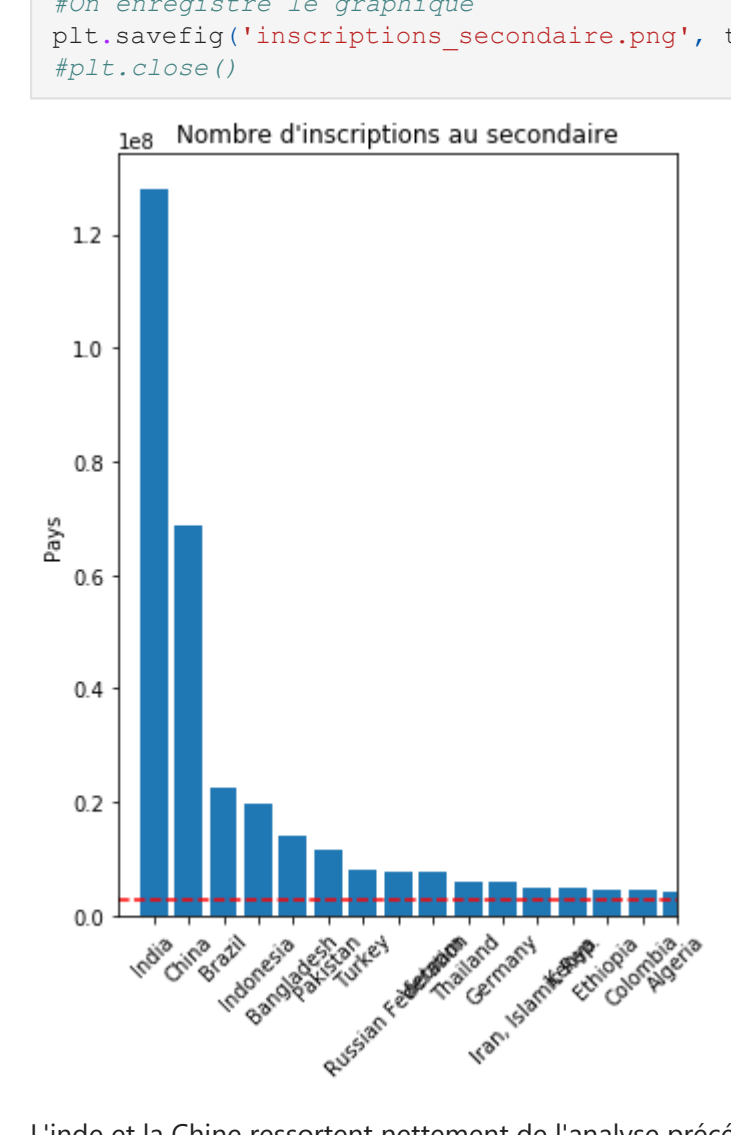

L'inde et la Chine ressortent nettement de l'analyse précédente.

Voyons maintenant l'évolution du nombre d'inscriptions au fil des années.

In [87]:
```
#On trace l'évolution du taux d'accès à internet de chaque pays

data = inscription_secondaire.loc[:15,:]
annees = ['2010','2011','2012','2013','2014','2015','2016']

fig, ax = plt.subplots(figsize=(10, 10))

#On trace les courbes de chaque pays
for i in data.itertuples():

    ax.plot(annees, data.loc[i[0],'2010':'2016'],\
            label=data.loc[i[0],'Country Name'])

#On paramètre la ligne de la moyenne
ax.axhline(moyenne_secondaire, ls='--', color='r')

#On paramètre le graphique et on l'affiche
ax.set(title="Evolution des inscriptions au secondaire")
ax.legend()

#On enregistre le graphique
plt.savefig('evolution_secondaire.png', transparent = True, dpi = 700)

plt.show()
```

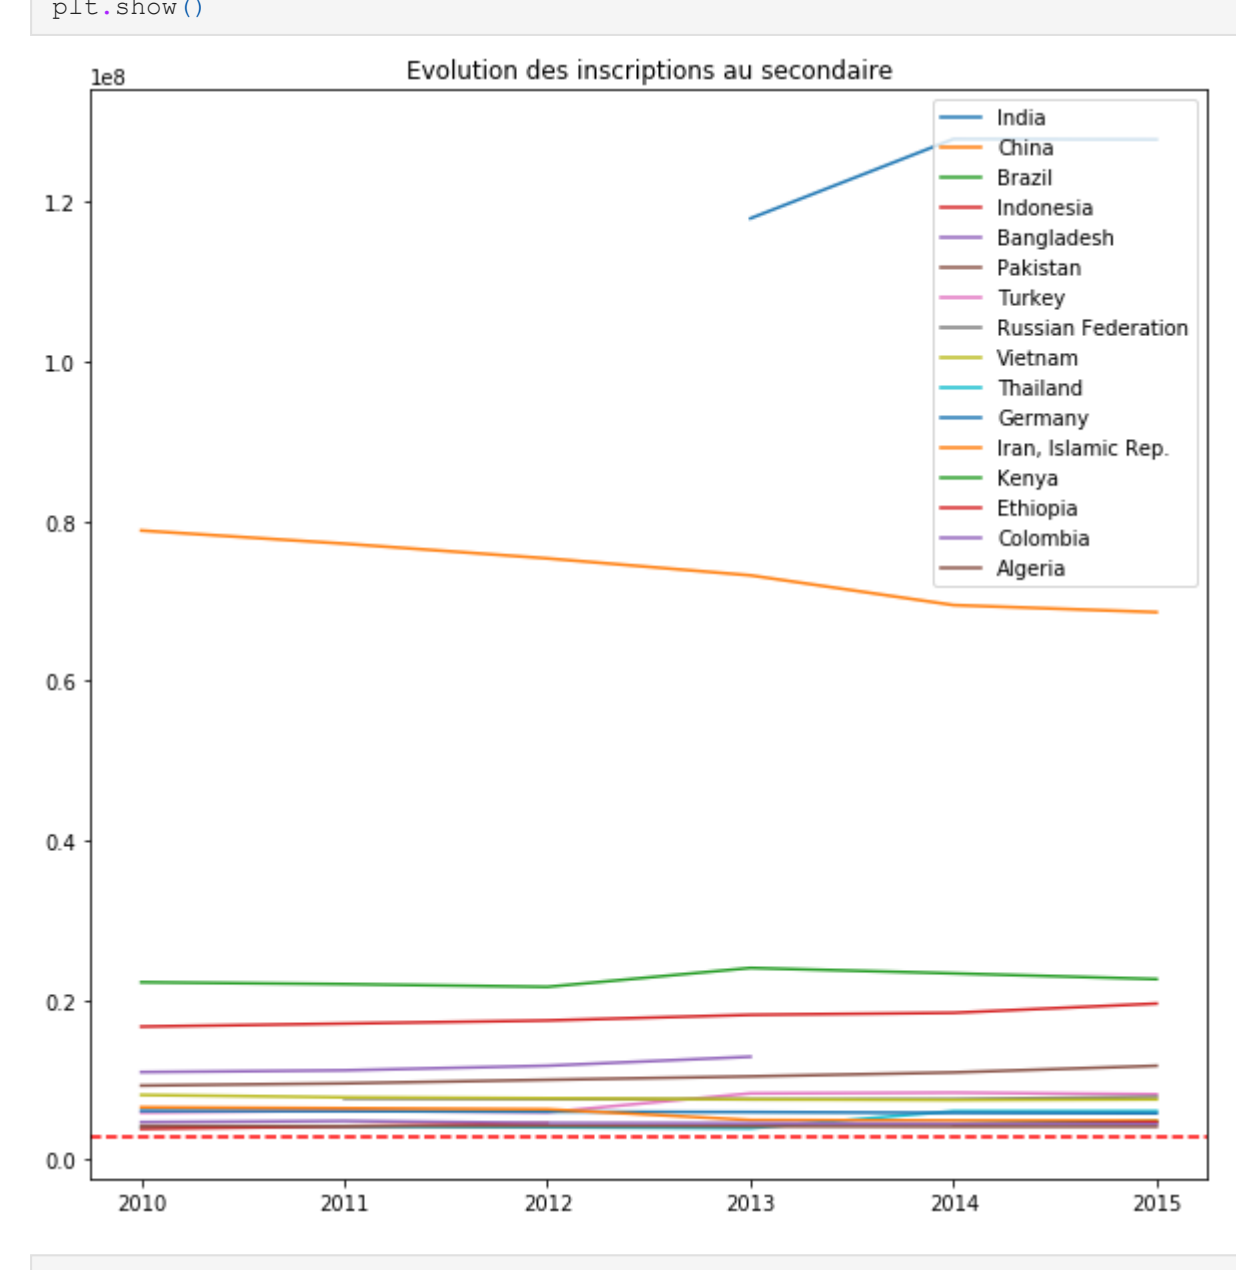

In [91]:
```
#On trace un graphique pour illustrer l'état des lieu des inscriptions au secondaire

fig, ax = plt.subplots(figsize=(6, 6))

labels = 'Pays au dessus de la moyenne', 'Pays en dessous de la moyenne'
sizes = [pays_sup.shape[0], pays_inf.shape[0]]
explode = (0.1, 0.1,)
colors = ['lightskyblue', 'lightslategray',]

plt.title("Moyenne d'accès à internet = 51.4%")
plt.pie(sizes, explode=explode, autopct='%1.1f%%', colors=colors,shadow=True, startangle=90)
plt.legend(bbox_to_anchor = (1, 1), loc = 'best', labels=labels)

#plt.axis('equal')

plt.rcParams['svg.fonttype'] = 'none'
plt.savefig('Moyenne_secondaire.png',transparent=True)
plt.show()
```

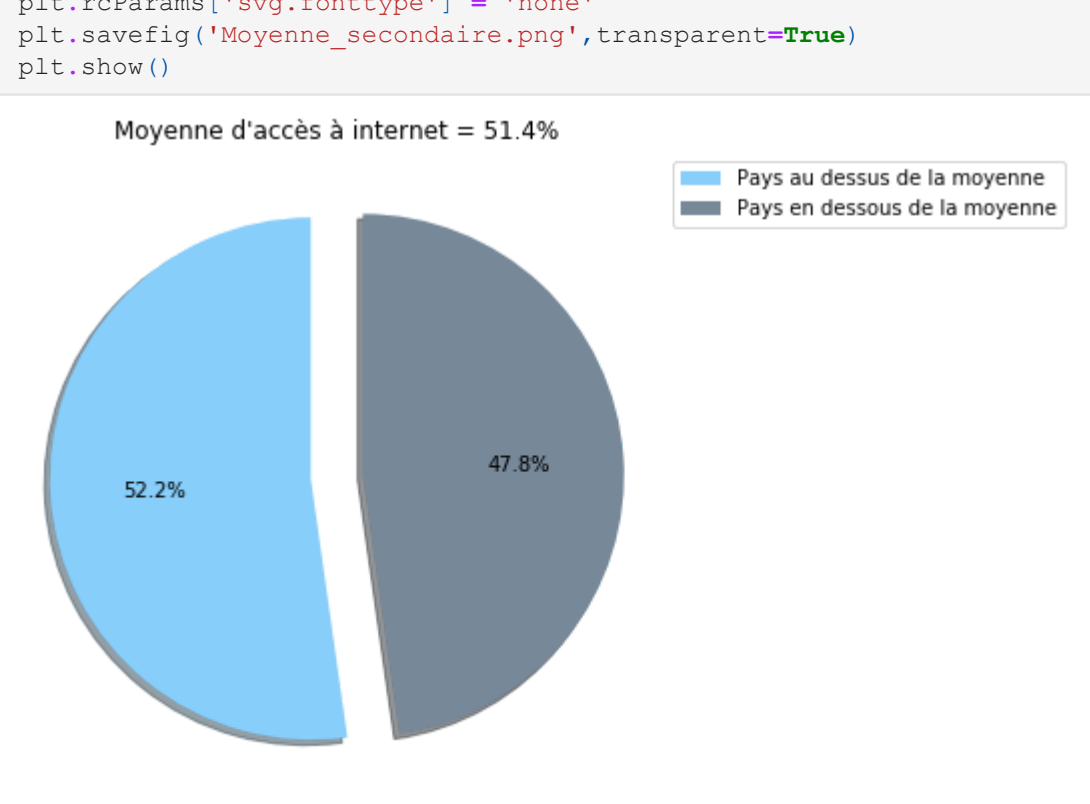

Après le secondaire, nous allons analyser l'enseignement supérieur. La cible directe de l'entreprise.

In [92]:
```
#Nous allons créer un tableau contenant tous les indicateurs se rapportant au secondaire avec le taux de
#remplissage de données pour chaque indicateur.
indicateurs_ens_sup_total = pd.DataFrame(columns=['Pays','Code Indicateur','Taux de remplissage'])

#Nous bouclons sur la liste des régions
for i in data_par_pays.itertuples():

    if 'SE.TER.' in data_par_pays.loc[i[0],'Indicator Code']:

        #On analyse les données sur 8 colonnes de 2010 à 2017
        nbr_donnees_totales = 8
        nbr_donnees_nulles = data_par_pays.loc[i[0],'2010':'2017'].isnull().sum().sum()
        taux_remplissage_indicateur = 100-(nbr_donnees_nulles / nbr_donnees_totales)*100

        #On incrémente ensuite le tableau de sortie
        indicateurs_ens_sup_total = \
            indicateurs_ens_sup_total.append({'Pays':data_par_pays.loc[i[0],'Country Name'], \
                                              'Code Indicateur':data_par_pays.loc[i[0],'Indicator Code'], \
                                              'Taux de remplissage':taux_remplissage_indicateur}, ignore_index

indicateurs_ens_sup_total.head()
```
Out[92]:

	Pays	Code Indicateur	Taux de remplissage
0	Afghanistan	SE.TER.ENRL	25.0
1	Afghanistan	SE.TER.ENRL.FE	25.0
2	Afghanistan	SE.TER.GRAD	12.5
3	Afghanistan	SE.TER.GRAD.FE	12.5
4	Afghanistan	SE.TER.ENRR	25.0

In [93]:
```
#Calcul du taux de remplissage par indicateur
indic_ens_sup_unique = indicateurs_ens_sup_total['Code Indicateur'].unique().tolist()

tab_moy_indic_ens_sup = pd.DataFrame(columns=['Code Indicateur', 'Moyenne'])

for i in range(len(indic_sec_unique)):
    masque = indicateurs_ens_sup_total[indicateurs_ens_sup_total['Code Indicateur'] == \
                                       indic_ens_sup_unique[i]]

    moyenne = masque['Taux de remplissage'].mean()

    #On incrémente ensuite le tableau de sortie
    tab_moy_indic_ens_sup = \
        tab_moy_indic_ens_sup.append({'Code Indicateur':indic_ens_sup_unique[i], \
                                      'Moyenne':moyenne}, ignore_index=True)

tab_moy_indic_ens_sup = tab_moy_indic_ens_sup.sort_values(by = 'Moyenne', ascending = False)
tab_moy_indic_ens_sup.head()
```
Out[93]:

	Code Indicateur	Moyenne
7	SE.TER.PRIV.ZS	49.176647
19	SE.TER.ENRL.FE.ZS	48.989899
0	SE.TER.ENRL	48.953202
4	SE.TER.ENRR	48.840206
5	SE.TER.ENRR.FE	48.177083

In [94]:
```
moyenne_indic_sup = tab_moy_indic_ens_sup['Moyenne'].mean()
moyenne_indic_sup
```
Out[94]: 36.25818546658011

In [95]:
```
#On crée un graphique en barres verticales avec la moyenne pour visualiser quels sont pays au-dessus et en-d
name = tab_moy_indic_ens_sup['Code Indicateur']
data = tab_moy_indic_ens_sup['Moyenne']

#On dimensionne le graphique
fig, ax = plt.subplots(figsize=(15, 8))

#On paramètre les barres avec les données et les labels
ax.bar(name, data)

#On paramètre la ligne de la moyenne
ax.axhline(moyenne_indic_sup, ls='--', color='r')

#On dit que les labels vont sur l'axe X
labels = ax.get_xticklabels()

#On les réoriente à 85°
plt.setp(labels, rotation=85)

#On modifie la taille de police des labels
plt.xticks(fontsize=8)

#On paramètre le grtaphique et on l'affiche
ax.set(xlim=[-1, tab_moy_indic_ens_sup.shape[0]], xlabel='Indicateurs', ylabel='% de données',
       title="Taux de données par indicateur")

#On enregistre le graphique
plt.savefig('Indic_ens_sup.png', transparent = True, dpi = 700)
```

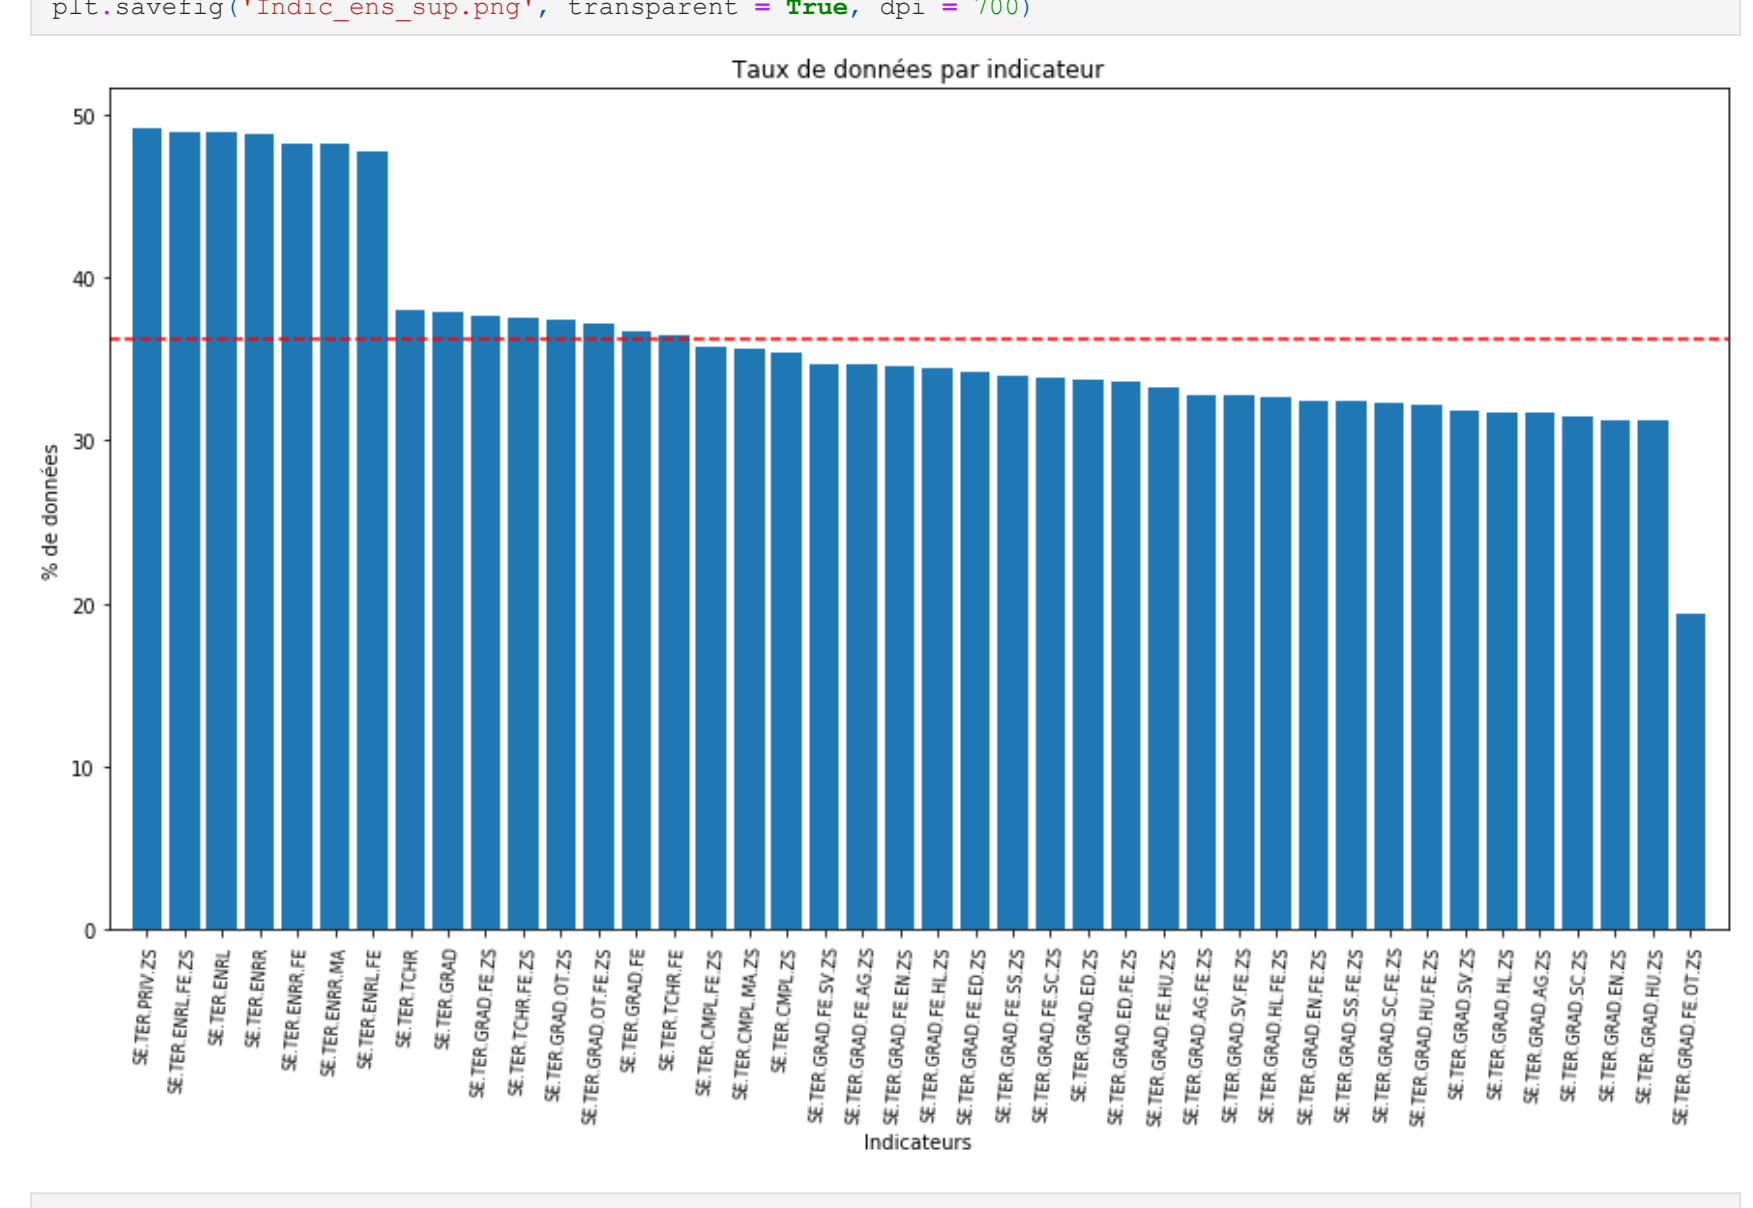

In [96]:
```
#On recherche quels sont les noms des indicateurs les plus remplis
nom_indic_sup = data_par_pays[data_par_pays['Indicator Code'].isin(['SE.TER.PRIV.ZS', 'SE.TER.ENRL.FE.ZS',\
                                                                    'SE.TER.ENRL','SE.TER.ENRR'])]
nom_indic_sup.head()
```
Out[96]:

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	1975
92829	Afghanistan	AFG	Enrolment in tertiary education, all programme...	SE.TER.ENRL	7732.00000	9409.00000	9817.00000	11487.00000	10956.00000	12256.00000
92964	Afghanistan	AFG	Gross enrolment ratio, tertiary, both sexes (%)	SE.TER.ENRR	0.76817	0.92394	0.95241	1.09745	1.02620	1.08012
93482	Afghanistan	AFG	Percentage of enrolment in tertiary education ...	SE.TER.PRIV.ZS	NaN	NaN	NaN	NaN	NaN	NaN
93675	Afghanistan	AFG	Percentage of students in tertiary education w...	SE.TER.ENRL.FE.ZS	14.67926	NaN	13.34420	15.44354	13.64549	13.71573
96494	Albania	ALB	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	25469.00000	28668.00000	NaN	NaN	NaN

5 rows × 70 columns

In [97]:
```
len(indic_ens_sup_unique)
```
Out[97]: 43

On va analyser maintenant les pays avec un indicateur important pour l'analyse :

Le plus fort taux d'inscription en enseignement supérieur : SE.TER.ENRL

Attention cependant, le remplissage de cet indicateur s'arrête en 2015!

In [98]:
```
#On va analyser maintenant les pays avec le plus fort taux d'inscription en enseignement supérieur.
#On recherche l'indicateur qui identifie les inscriptions par pays
enseignement_superieur = data_par_pays.loc[data_par_pays['Indicator Code'] ==  'SE.TER.ENRL',:]
enseignement_superieur.shape
```
Out[98]: (203, 70)

In [101…
```
#On tri dans l'ordre décroissant les pays avec le plus d'inscriptions
enseignement_superieur= enseignement_superieur.sort_values(by = '2015', ascending = False)
enseignement_superieur.head()
```
Out[101…

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	1975	...	2060	2065
243094	China	CHN	Enrolment in tertiary education, all programme...	SE.TER.ENRL	108617.0	NaN	NaN	193719.0	313645.0	429981.0	...	NaN	NaN
415349	India	IND	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	2472963.0	NaN	2773148.0	NaN	NaN	...	NaN	NaN
847819	United States	USA	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	8498117.0	8948645.0	9297787.0	9602123.0	10223729.0	...	NaN	NaN
188119	Brazil	BRA	Enrolment in tertiary education, all programme...	SE.TER.ENRL	430473.0	569230.0	696215.0	785159.0	954674.0	1089808.0	...	NaN	NaN
679229	Russian Federation	RUS	Enrolment in tertiary education, all programme...	SE.TER.ENRL	5212600.0	5277900.0	5308700.0	5356500.0	5403300.0	5470900.0	...	NaN	NaN

5 rows × 70 columns

In [102…
```
#Nous allons analyser l'évolution du taux de données pour cet indicateur

#Nous créons un nouveau dataframe dans lequel seront stockés les résultats
tab_taux_superieur = pd.DataFrame(columns=['Année','taux de données (%)'])

#Nous bouclons sur les colonnes correspondant aux années
j=2010

while j <= 2017:

    nbr_donnees_totales = enseignement_superieur.shape[0]

    nbr_donnees_nulles = enseignement_superieur.loc[:,str(j)].isnull().sum().sum()

    taux_remplissage_superieur = 100-(nbr_donnees_nulles / nbr_donnees_totales)*100

    tab_taux_superieur = \
        tab_taux_superieur.append({'Année':j,'taux de données (%)':taux_remplissage_superieur}, ignore_index
    j+=1

print(tab_taux_superieur)
```
```
    Année  taux de données (%)
0  2010.0            68.965517
1  2011.0            69.950739
2  2012.0            69.458128
3  2013.0            64.532020
4  2014.0            61.083744
5  2015.0            54.187192
6  2016.0             3.448276
7  2017.0             0.000000
```

In [103…
```
#On calcule la moyenne d'inscriptions en enseignement supérieur pour l'année 2015 qui est l'année
#avec un taux de données exploitables
moyenne_ens_sup = enseignement_superieur['2015'].mean()
moyenne_ens_sup
```
Out[103… 1573104.5053977272

In [104…
```
#Une fois que la moyenne a été calculée, nous pouvons rechercher les pays au-dessus de cette moyenne
moyenne_ens_sup_sup = enseignement_superieur[enseignement_superieur['2015'] > moyenne_ens_sup]
moyenne_ens_sup_sup.shape
```

Out[104…: (18, 70)

In [105…:

```python
#Une fois que la moyenne a été calculée, nous pouvons rechercher les pays au-dessus de cette moyenne
moyenne_ens_sup_inf = enseignement_superieur[enseignement_superieur['2015'] < moyenne_ens_sup]
moyenne_ens_sup_inf.shape
```

Out[105…: (92, 70)

In [106…:

```python
#On crée un graphique en barres verticales avec la moyenne pour visualiser quels sont pays au-dessus et en-d

#On ne va analyser que les 5 premiers pays
#On reset l'index avant. Cela permettra de récupérer suelement les 5 premières lignes
enseignement_superieur = enseignement_superieur.reset_index(drop=True)
enseignement_superieur = enseignement_superieur.loc[:15,:]

name = enseignement_superieur['Country Name']
data = enseignement_superieur['2015']

#On dimensionne le graphique
fig, ax = plt.subplots(figsize=(5, 7))

#On paramètre les barres avec les données et les labels
ax.bar(name, data, width=0.8)


#On paramètre la ligne de la moyenne
ax.axhline(moyenne_ens_sup, ls='--', color='r')

#On dit que les labels vont sur l'axe X
labels = ax.get_xticklabels()

#On les réoriente à 45°
plt.setp(labels, rotation=45)

#On paramètre le graphique et on l'affiche
ax.set(xlim=[-1, enseignement_superieur.shape[0]],  ylabel='Pays',
       title="Nombre d'inscriptions en enseignement sup")

#On enregistre le graphique
plt.savefig('inscriptions_ens_sup.png', transparent = True, dpi = 700)
#plt.close()
```

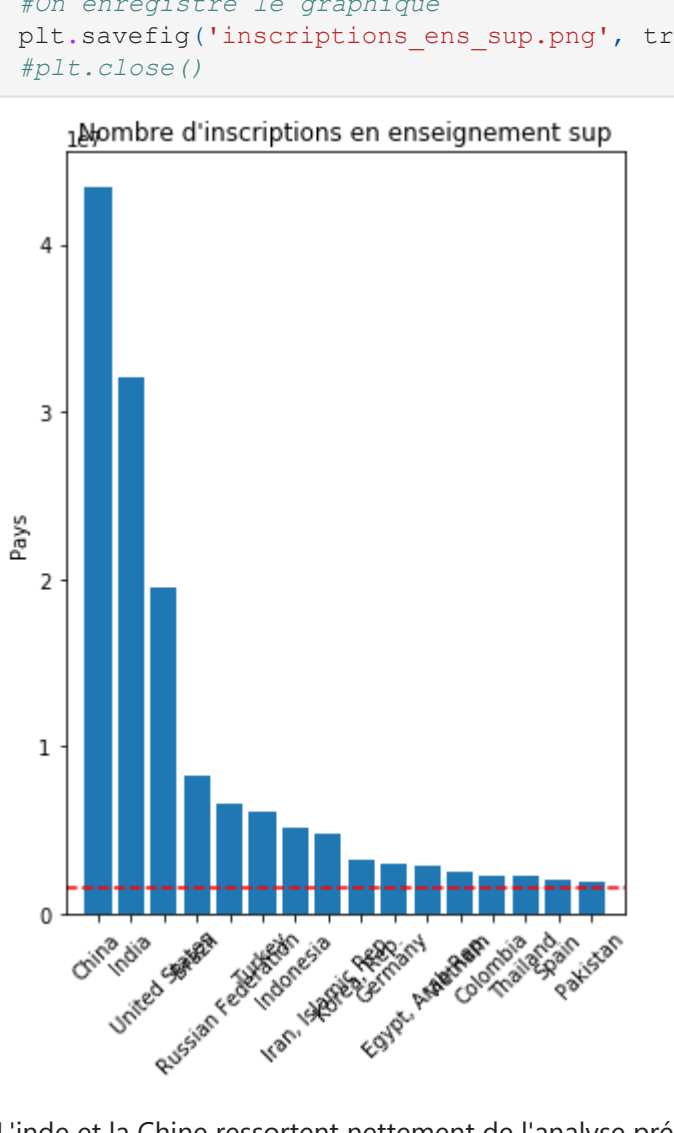

L'inde et la Chine ressortent nettement de l'analyse précédente.

Voyons maintenant l'évolution du nombre d'inscriptions au fil des années.

In [107…:

```python
#On va superposer l'évolution des inscriptions au secondare des 5 pays à fort potentiel

pays_1 = enseignement_superieur.loc[0,'2010':'2016']
pays_2 = enseignement_superieur.loc[1,'2010':'2016']
pays_3 = enseignement_superieur.loc[2,'2010':'2016']
pays_4 = enseignement_superieur.loc[3,'2010':'2016']
pays_5 = enseignement_superieur.loc[4,'2010':'2016']

annees = ['2010','2011','2012','2013','2014','2015','2016']

fig, ax = plt.subplots()
ax.plot(annees, pays_1, label=enseignement_superieur.loc[0,'Country Name'])
ax.plot(annees, pays_2, label=enseignement_superieur.loc[1,'Country Name'])
ax.plot(annees, pays_3, label=enseignement_superieur.loc[2,'Country Name'])
ax.plot(annees, pays_4, label=enseignement_superieur.loc[3,'Country Name'])
ax.plot(annees, pays_5, label=enseignement_superieur.loc[4,'Country Name'])

#On paramètre la ligne de la moyenne
ax.axhline(moyenne_ens_sup, ls='--', color='r')

#On paramètre le graphique et on l'affiche
ax.set(title="Evolution des inscriptions en enseignement sup")

ax.legend()

#On enregistre le graphique
plt.savefig('evolution_ens_sup.png', transparent = True, dpi = 700)

plt.show()
```

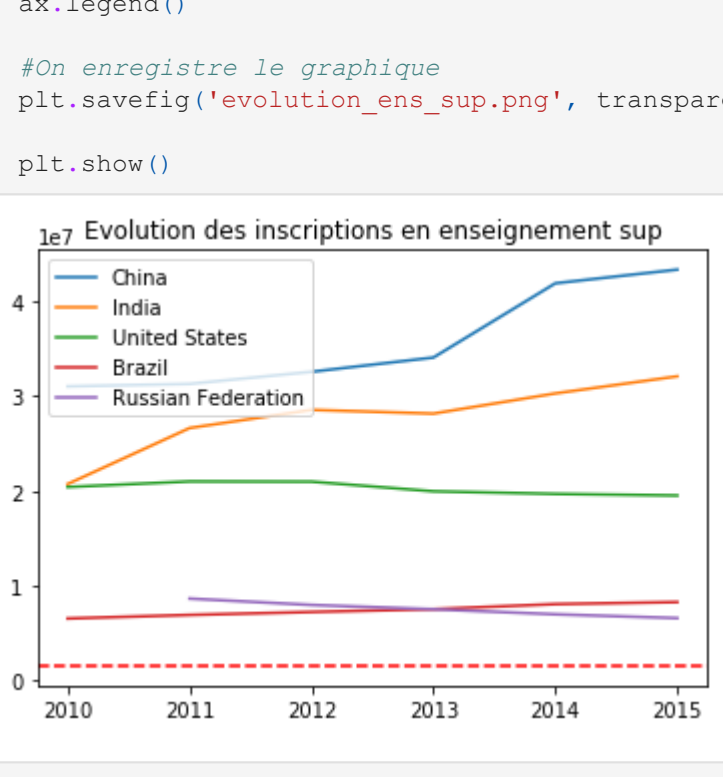

In [108…:

```python
#On trace un graphique pour illustrer l'état des lieu des inscriptions en enseignement sup

fig, ax = plt.subplots(figsize=(6, 6))

#labels = 'Pays au dessus de la moyenne', 'Pays en dessous de la moyenne'
sizes = [moyenne_ens_sup_sup.shape[0], moyenne_ens_sup_inf.shape[0]]
explode = (0.1, 0.1,)
colors = ['lightskyblue', 'lightslategray',]

#plt.title("Moyenne d'accès à internet = 51.4%")
plt.pie(sizes, explode=explode, autopct='%1.1f%%', colors=colors,shadow=True, startangle=90)

#plt.axis('equal')

plt.rcParams['svg.fonttype'] = 'none'
plt.savefig('Moyenne_ens_sup.png',transparent=True)
plt.show()
```

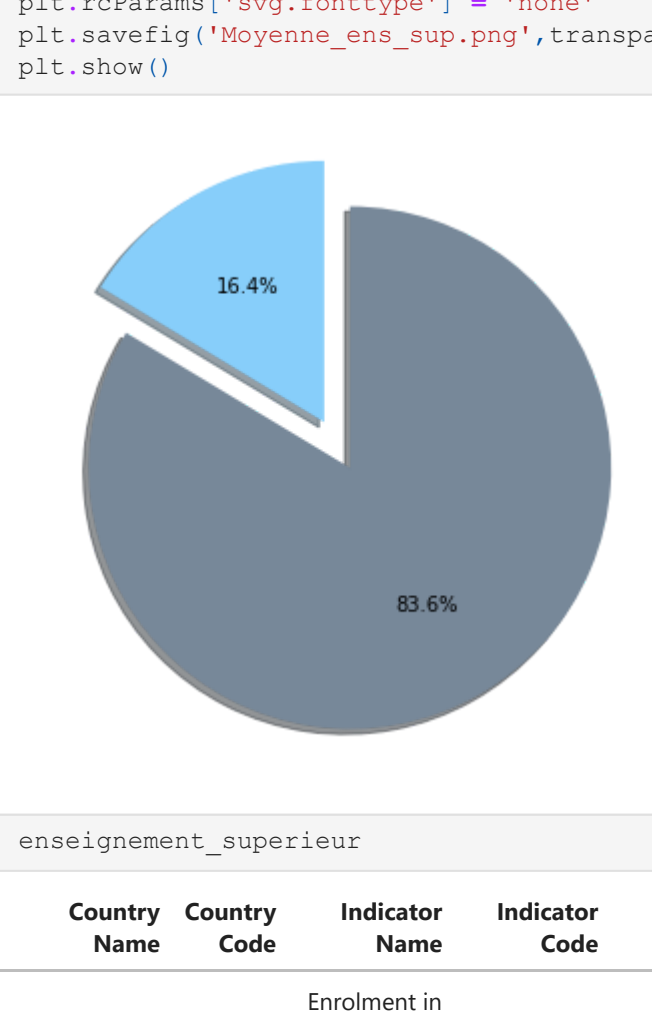

In [80]:

```python
enseignement_superieur
```

Out[80]:

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	1975	...	2060	2065	2070
0	China	CHN	Enrolment in tertiary education, all programme...	SE.TER.ENRL	108617.0	NaN	NaN	193719.0	313645.0	429981.0	...	NaN	NaN	NaN
1	India	IND	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	2472963.0	NaN	2773148.0	NaN	NaN	...	NaN	NaN	NaN
2	United States	USA	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	8498117.0	8948645.0	9297787.0	9602123.0	10223729.0	...	NaN	NaN	NaN
3	Brazil	BRA	Enrolment in tertiary education, all programme...	SE.TER.ENRL	430473.0	569230.0	696215.0	785159.0	954674.0	1089808.0	...	NaN	NaN	NaN
4	Russian Federation	RUS	Enrolment in tertiary education, all programme...	SE.TER.ENRL	5212600.0	5277900.0	5308700.0	5356500.0	5403300.0	5470900.0	...	NaN	NaN	NaN
5	Turkey	TUR	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	169793.0	169672.0	172075.0	185285.0	263990.0	...	NaN	NaN	NaN

6 rows × 70 columns

Après analyse du secondaire et du supérieur, il ressort 3 pays :

- La Chine
- L'inde
- Les Etats-Unis (Il n'y a pas de données dans le dataset pour le secondaire)

Nous allons maintenant sortir une fiche plus détaillée de ces 3 pays contenant :

- La population totale
- L'accès à internet
- Le taux d'inscription en enseignement secondaire
- Le taux d'inscription en enseignement sup
- Le PIB par habitant

In [182…:

```python
#Nous allons maintenant analyser les évolutions des pays les plus intéressants pour l'entreprise
#Pour cela on commence par trier les 8 pays au plus fort PIB par habitant

analyse_pays_hyp2 = data_par_pays[data_par_pays['Country Name'].isin(['India','China','United States'])]

analyse_pays_hyp2 = analyse_pays_hyp2[analyse_pays_hyp2['Indicator Code']\
                                       .isin(['SE.TER.ENRL', 'NY.GDP.PCAP.CD',\
                                              'IT.NET.USER.P2','SE.SEC.ENRL.GC','SP.POP.TOTL'])]

analyse_pays_hyp2 = analyse_pays_hyp2.reset_index(drop=True)

#On enregistre le tableau dans un doc excel
#fichier_excel = pd.ExcelWriter('Analyse_pays_hyp2.xlsx')
#analyse_pays_hyp2.to_excel(fichier_excel, "Sheet1")
#fichier_excel.save()

analyse_pays_hyp2
```

Out[182…:

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	1975
0	China	CHN	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	2.021490e+07	2.641850e+07	3.127610e+07	3.582440e+07	3.446430e+07	3.650360e+07
1	China	CHN	Enrolment in tertiary education, all programme...	SE.TER.ENRL	1.086170e+05	NaN	NaN	1.937190e+05	3.136450e+05	4.299810e+05
2	China	CHN	GDP per capita (current US$)	NY.GDP.PCAP.CD	1.131630e+02	1.186546e+02	1.318836e+02	1.570904e+02	1.601401e+02	1.783418e+02
3	China	CHN	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN
4	China	CHN	Population, total	SP.POP.TOTL	8.183150e+08	8.411050e+08	8.620300e+08	8.819400e+08	9.003500e+08	9.163950e+08
5	India	IND	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	2.092450e+07	2.173648e+07	2.259896e+07	NaN	2.426348e+07
6	India	IND	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	2.472963e+06	NaN	2.773148e+06	NaN	NaN
7	India	IND	GDP per capita (current US$)	NY.GDP.PCAP.CD	1.112576e+02	1.173607e+02	1.216923e+02	1.422701e+02	1.617630e+02	1.563801e+02
8	India	IND	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN
9	India	IND	Population, total	SP.POP.TOTL	5.535785e+08	5.662248e+08	5.794115e+08	5.930589e+08	6.070503e+08	6.213017e+08
10	United States	USA	Enrolment in secondary general, both sexes (nu...	SE.SEC.ENRL.GC	NaN	2.059300e+07	2.116100e+07	NaN	2.159100e+07	2.165600e+07
11	United States	USA	Enrolment in tertiary education, all programme...	SE.TER.ENRL	NaN	8.498117e+06	8.948645e+06	9.297787e+06	9.602123e+06	1.022373e+07
12	United States	USA	GDP per capita (current US$)	NY.GDP.PCAP.CD	5.246884e+03	5.623444e+03	6.109926e+03	6.741332e+03	7.242441e+03	7.820065e+03
13	United States	USA	Internet users (per 100 people)	IT.NET.USER.P2	NaN	NaN	NaN	NaN	NaN	NaN
14	United States	USA	Population, total	SP.POP.TOTL	2.050520e+08	2.076610e+08	2.098960e+08	2.119090e+08	2.138540e+08	2.159730e+08

15 rows × 70 columns

In [350…:

```python
plt.figure(1,figsize=(15, 10))

ax1 = plt.subplot(1, 2, 1)

data = analyse_pays_hyp2.loc[analyse_pays_hyp2['Indicator Code'] == 'IT.NET.USER.P2']
annees = ['2010','2011','2012','2013','2014','2015','2016']

#On trace les courbes de chaque pays
for i in data.itertuples():

    if data.loc[i[0],'Country Name'] == 'United States':
        ax1.plot(annees, data.loc[i[0],'2010':'2016'],\
                 label=data.loc[i[0],'Country Name'], marker = 'o',color = 'coral')

    elif data.loc[i[0],'Country Name'] == 'China':
        ax1.plot(annees, data.loc[i[0],'2010':'2016'],\
                 label=data.loc[i[0],'Country Name'], marker = 'o',color = 'lightskyblue')

    elif data.loc[i[0],'Country Name'] == 'India':
        ax1.plot(annees, data.loc[i[0],'2010':'2016'],\
                 label=data.loc[i[0],'Country Name'], marker = 'o',color = 'lightslategray')

#On paramètre le graphique et on l'affiche
ax1.set(title="Evolution accès internet")

ax1.legend(loc = 'upper left', prop = {'size': 10})
ax1.text(5.9, 77, '76%', fontsize = 10, color = 'black')
ax1.text(5.9, 54.5, '53%', fontsize = 10, color = 'black')
ax1.text(5.7, 30.5, '29.5%', fontsize = 10, color = 'black')

ax2 = plt.subplot(2, 2, 2)

#On construit tout d'abord les données à tracer
#On appelle la fonction qui nous trie le dataset de base en fonction d'un indicateur
data = filtre_indicateur(data_par_pays,'NY.GDP.PCAP.CD')

#Ensuite on trie le résultat par ordre décroissant suivant une colonne donnée
#Ici 2016, est la dernière année contenant des données
data = data.sort_values(by = '2016', ascending = False)

#Le tri précédent ayant aussi modifié l'ordre des lignes, on remet l'index du dataframe à 0
data = data.reset_index(drop = True)

#Enfin, on supprime les lignes contenant des valeurs nulles
data = list(data['2016'].dropna())

ax2.boxplot(data,whis=[5,95])

#On paramètre le graphique et on l'affiche
ax2.set(ylim=[0,60000],title="Analyse PIB par habitant en 2016", ylabel='Dollars ($)')

ax2.text(1.1, 4400, 'Médiane : 5219$', fontsize = 10, color = 'coral')
ax2.text(1.1, 200, "5% de l'échantillon", fontsize = 10, color = 'black')
ax2.text(1.1, 51000, "95% de l'échantillon", fontsize = 10, color = 'black')

ax2.text(0.52, 58000, 'United States : : 57638.2$', fontsize = 10, color = 'coral')
ax2.text(0.52, 55000, 'China : 8123.2$', fontsize = 10, color = 'lightskyblue')
ax2.text(0.52, 52000, 'India : 1710$', fontsize = 10, color = 'lightslategray')

ax3 = plt.subplot(2, 2, 4)

data = analyse_pays_hyp2.loc[analyse_pays_hyp2['Indicator Code'] == 'SP.POP.TOTL']
data = data['2016']

labels = analyse_pays_hyp2['Country Name'].unique()

explode = (0.1, 0.1, 0.1)
colors = ['lightskyblue', 'lightslategray','coral']

ax3.set(title="Population totale en 2016")
ax3.pie(data, explode=explode, autopct='%1.1f%%', colors=colors,shadow=True, startangle=90)
ax3.legend(bbox_to_anchor = (1, 1), loc = 'best', labels=labels)
```

Out[350…: <matplotlib.legend.Legend at 0x2a842fe0828>

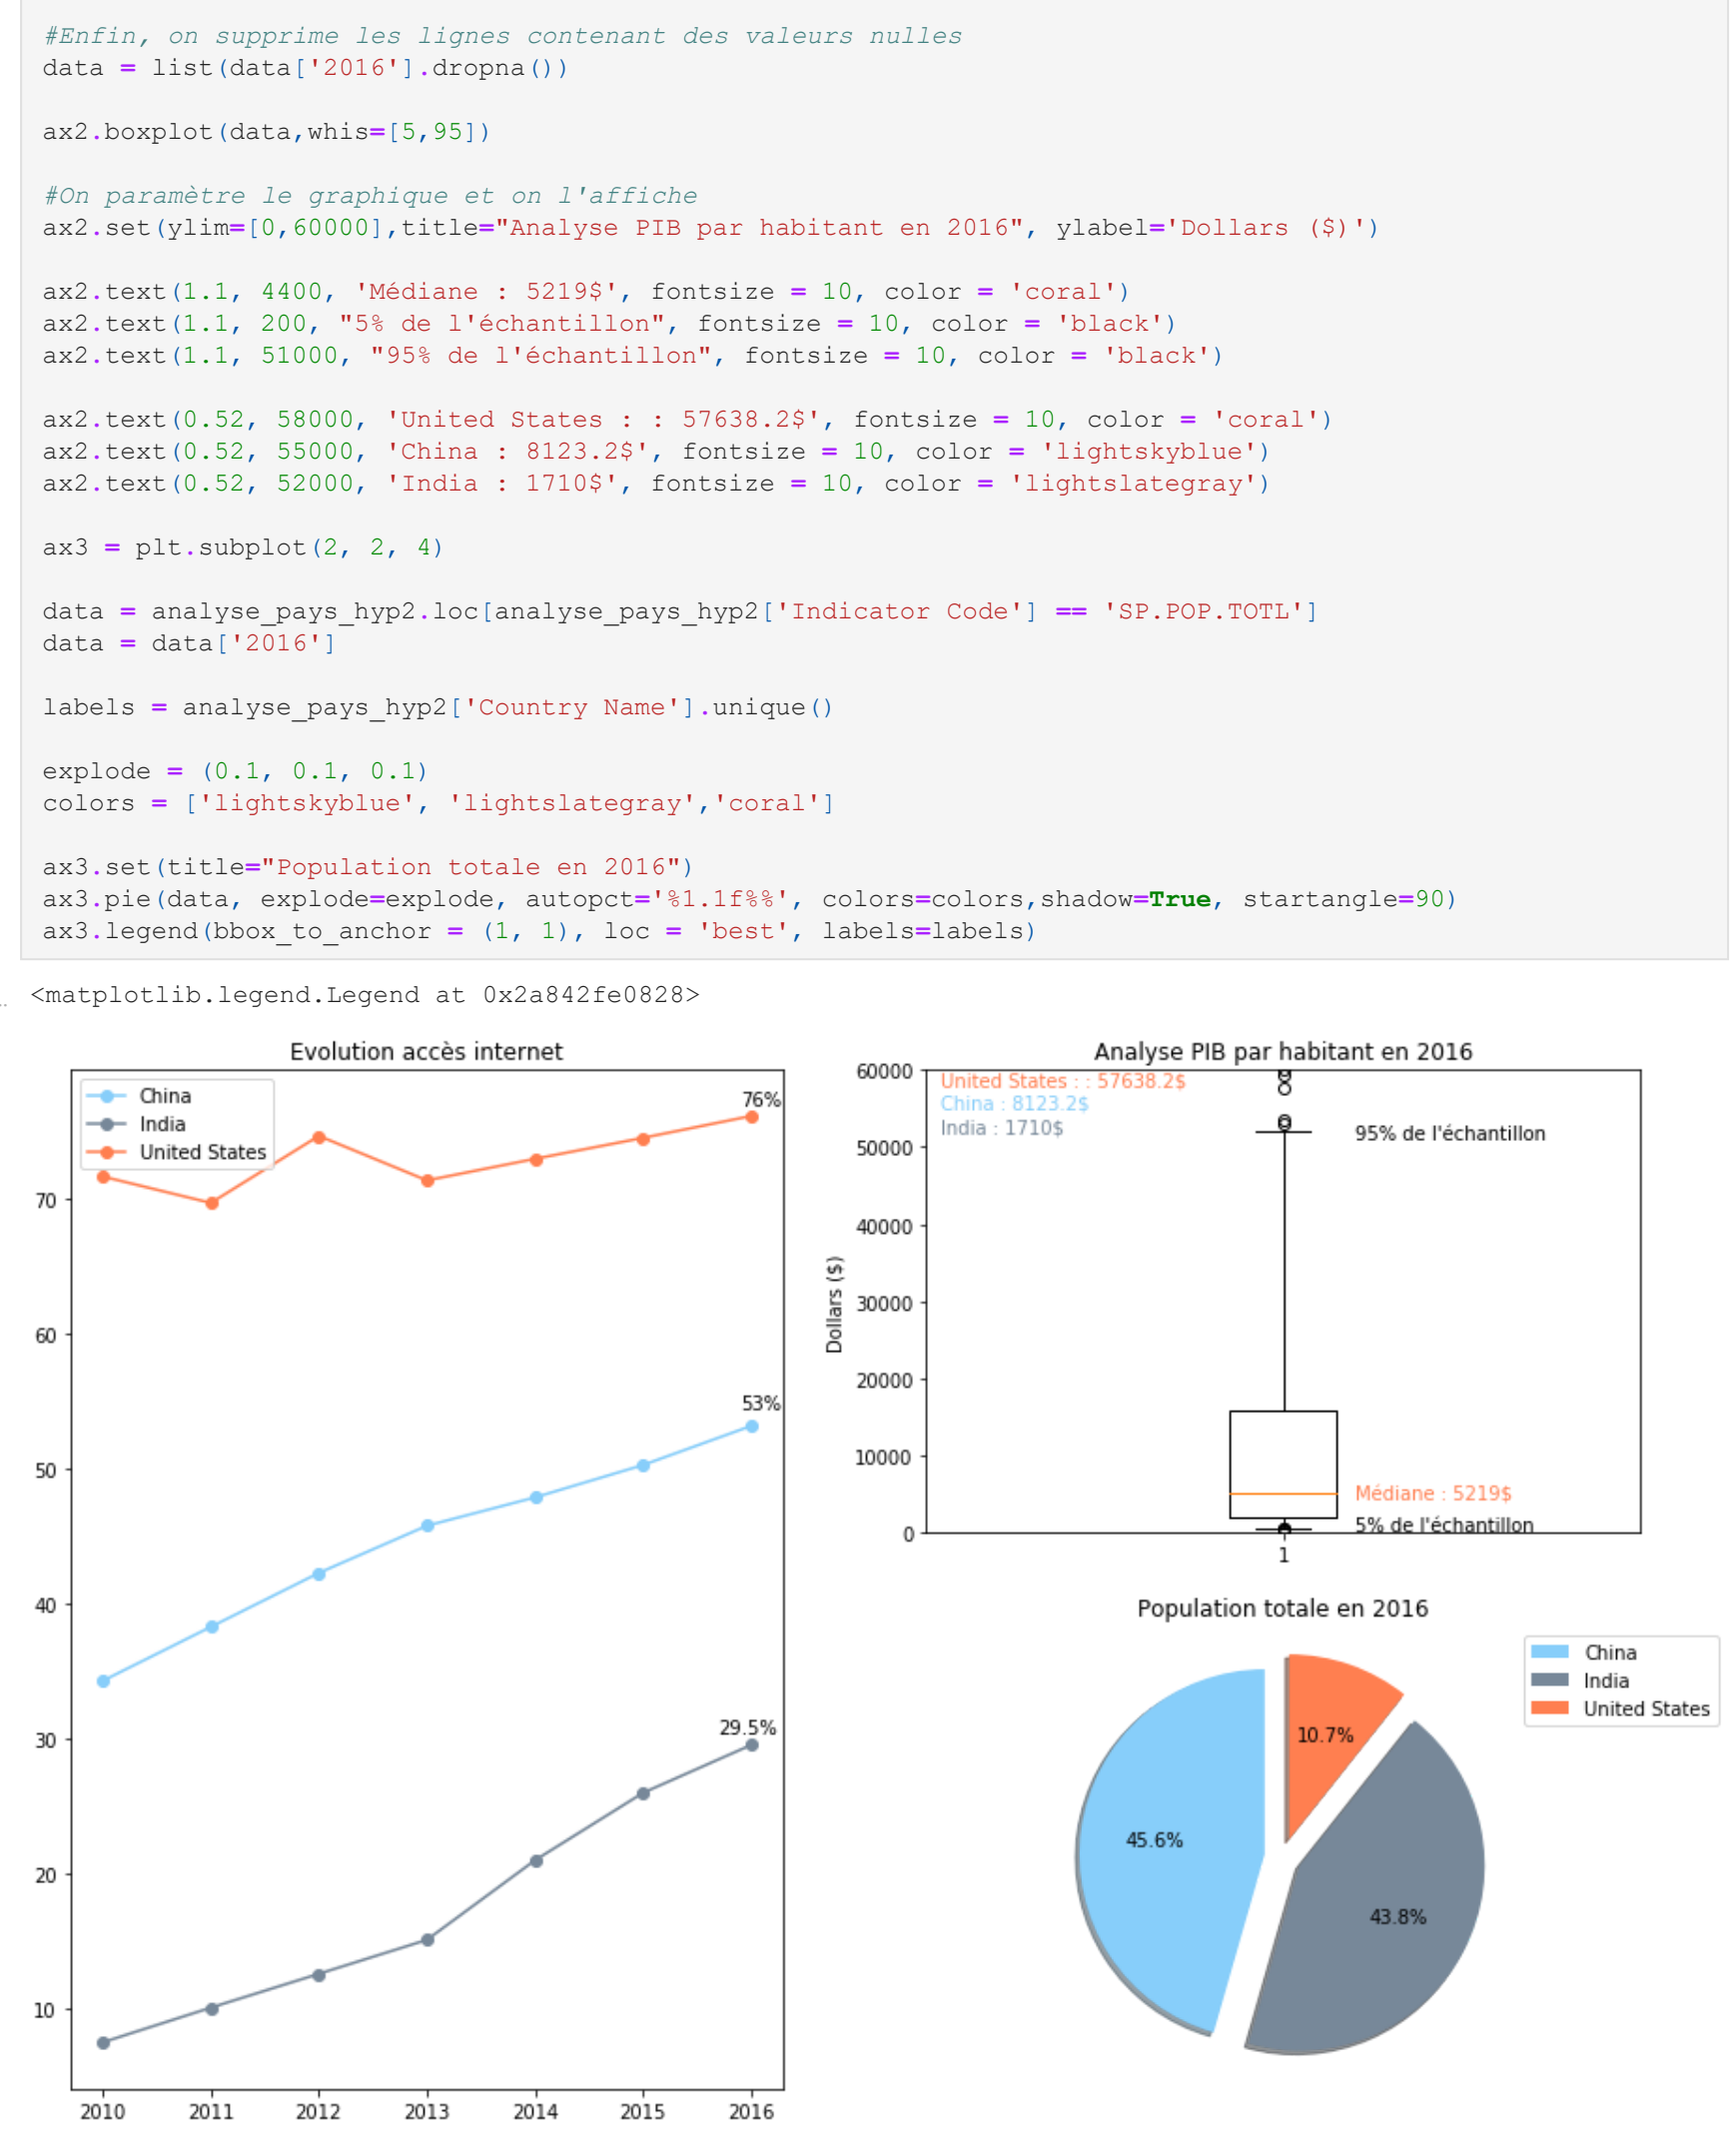

In [269…:

```python
#On crée un graphique pour visualiser le nombre d'inscriptions au secondaire et supérieur

#On dimensionne le graphique
fig, ax = plt.subplots(figsize=(15, 7))

name = analyse_pays_hyp2['Country Name'].unique()

#On construit les barres pour le secondaire
inscriptions_sec = analyse_pays_hyp2.loc[analyse_pays_hyp2['Indicator Code'] == 'SE.SEC.ENRL.GC']
inscriptions_sec = inscriptions_sec['2015']

inscriptions_sup = analyse_pays_hyp2.loc[analyse_pays_hyp2['Indicator Code'] == 'SE.TER.ENRL']
inscriptions_sup = inscriptions_sup['2015']

barWidth = 0.4
position_sec = range(len(inscriptions_sec))
position_sup = [x + barWidth for x in position_sec]

bar1 = ax.bar(position_sec, inscriptions_sec, width = barWidth, color = 'lightskyblue')
bar2 = ax.bar(position_sup, inscriptions_sup, width = barWidth, color = 'lightslategray')

plt.xticks([r + barWidth / 2 for r in range(len(inscriptions_sec))], name)

plt.title("Nbr d'inscriptions en 2015", size=15)
ax.legend(['Inscriptions secondaire','Inscriptions supérieur'], loc = "upper right")

def autolabel(rects, xpos='center'):
    """
    Attach a text label above each bar in *rects*, displaying its height.

    *xpos* indicates which side to place the text w.r.t. the center of
    the bar. It can be one of the following {'center', 'right', 'left'}.
    """

    ha = {'center': 'center', 'right': 'left', 'left': 'right'}
    offset = {'center': 0, 'right': 1, 'left': -1}

    for rect in rects:
        height = rect.get_height()
        ax.annotate('{}'.format(height),
                    xy=(rect.get_x() + rect.get_width() / 2, height),
                    xytext=(offset[xpos]*3, 3),  # use 3 points offset
                    textcoords="offset points",  # in both directions
                    ha=ha[xpos], va='bottom')


autolabel(bar1, "center")
autolabel(bar2, "center")
```

Les indicateurs futurs

Afin d'appuyer l'analyse précédente, qui se porte que sur des indicateurs s'arrêtant maximum en 2016, j'ai cherché des indicateurs avec des données prévisionnelles.

J'ai choisi un indicateur intéressant (PRJ.POP.ALL.4.MF), qui représente la perspective de réussite en enseignement supérieur. C'est un point essentiel pour la réussite du

L'analyse qui suivra couvrera une période allant de 2020 à 2030.

In [354…:

```python
#on recherche les indicateurs contenant des données après 2017
#afin d'en identifier un qui pourrait nous montrer les tendances à venir sur un point qui nous interesserait

colonnes_a_tester = list(data_par_pays.loc[:,"2017":])

#Ensuite,on utilise le dropna()
#le paramètre how='all' configure la fonction pour qu'il teste que TOUTES les cellules soient vides
#Le subset, c'est la plage de cellules à tester. Celle qu'on a déterminé précédemment.
df = data_par_pays.dropna(how="all", subset=colonnes_a_tester)
df = df['Indicator Name'].unique()
df.shape
```

Out[354…: (348,)

In [362…:

```python
data = filtre_indicateur(data_par_pays,'PRJ.POP.ALL.4.MF')
data = data.sort_values(by = '2050', ascending = False)
data = data.reset_index(drop=True)
data = data.loc[:2,:]
data['2050']
```

Out[362…:

```
0    248880.50
1    237643.28
2    145446.92
Name: 2050, dtype: float64
```

In [396…:

```python
#On trace l'évolution du taux d'accès à internet de chaque pays

data = filtre_indicateur(data_par_pays,'PRJ.POP.ALL.4.MF')
data = data.sort_values(by = '2050', ascending = False)
data = data.reset_index(drop=True)
data = data.loc[:2,:]

annees = ['2015','2016','2017','2020','2025','2030','2035','2040','2045','2050']

fig, ax = plt.subplots(figsize=(10, 10))

#On trace les courbes de chaque pays
for i in data.itertuples():

    ax.plot(annees, data.loc[i[0],'2015':'2050'],\
            label=data.loc[i[0],'Country Name'],marker='o')

ax.legend(loc = 'upper left', prop = {'size': 10})
ax.text(9.6, 250880, '248880', fontsize = 10, color = 'black')
ax.text(9.6, 239643, '237643', fontsize = 10, color = 'black')
ax.text(9.6, 147446, '145446', fontsize = 10, color = 'black')

#On paramètre le graphique et on l'affiche
ax.set(title="Perspective de réussite en enseignement supérieur")

#On enregistre le graphique
plt.savefig('evol_pop_ens_sup.png', transparent = True, dpi = 700)

plt.show()
```


Conclusion

Voici ce que l'on peut conclure de toutes les analyses précédentes :

- Le taux de remplissage des données ciblant l'éducation est faible
- **Il existe plusieurs possibilités pour qu'Academy s'internationalise :**
  - S'implanter dans un pays où les infrastructures sont développées mais une population faible en enseignement supérieur :
  - Les formations Academy pourraient être un moteur pour la croissance de cette population
  - Qatar ou Macao en Chine
- **S'implanter dans un pays où les infrastructures sont développées et avec une population en enseignement supérieur intéressante :**
  - Les Etats-Unis ont un très fort potentiel
  - Norvège, Suisse, Irlande
- **S'implanter dans un pays plus pauvre mais avec une population en enseignement supérieur forte :**
  - Possibilité de formations gratuites? Financer par la publicité ou des aides de l'état par exemple
  - L'inde et la Chine

  Ceci conclue ce projet. Il n'y a pas de *bonne réponse* à une aide décisionnelle. Le but est d'explorer différentes hypothèses en se mettant à la place de l'entreprise et en se posant les bonnes questions. Nous avons développer deux hypothèses, nous aurions pu penser à d'avantages d'options. Attention toutefois à ne pas développer trop d'hypothèses, ce qui réduirait la pertinence de votre étude.

Merci et bravo d'être arrivé jusque là! N'hésitez pas à commenter, toutes remarques ou questions seront les bienvenues et surement utiles à d'autres personnes.

Julien Di Giulio

In [ ]: